

置顶任务调研报告

AI 剧目生成：官方评测竞赛、评测数据集、评价指标与工具调研

报告日期：2026 年 9 月 23 日

任务编号：置顶任务

AI 剧目生成：官方评测竞赛、评测数据集、评价指标与工具调研

本报告的立场：沿用任务 1 确立的划线标准——只认"有主办机制"的官方评测，社区基准单列说明。但本报告必须首先承认一个与前三份报告都不同的事实：**AI 视频生成领域目前不存在 TREC / IWSLT 那种官方技术评测**。这是一个必须先讲清楚的结论，而不是可以含糊过去的缺口。

第一章 任务概述

1.1 提示词回溯

本任务由用户在 2026 年 9 月 23 日追加，原文如下（节选）：

需求："我们需要的是能基于我们设备的前提下 高效制作AI剧目的程序 如果用现有市面上的比如即梦一类的软件 可能一台设备只能产出一部剧 我们的想法是争取一台设备同时能产出多部剧目 提高效率 辛苦Workbuddy帮助我们解决这些专业性强的领域"

要求："所以请创建名为'置顶任务：AI剧目生成'，至于公网主页的任务一前面，并对新任务生成类似任务1，任务2，任务3的成果，包括前世今生，国内外评测竞赛，评测数据集，评价指标与评测工具，技术路线等内容和调研报告"

随后用户追加了一篇微信公众号文章（虎鲸文娱「鲸锐 AI 创作大赛」），要求"深入研究"并入本任务。

把这轮提示词拆开，实际包含四个层次的要求：

层次	用户的话	对应本报告章节
业务痛点	一台设备只能出一部剧，想同时出多部	第四章 4.3、第八章
成果形式	与任务 1/2/3 对齐：前世今生、国内外评测竞赛、数据集、指标与工具、技术路线	第三、五、六、七章
载体要求	置顶到公网主页任务一之前 + 调研报告 PDF	交付物
深度研究	虎鲸文娱鲸锐大赛这篇公众号文章	第三章 3.5

1.2 需求界定：真正的问题不是"评测"，是"产能"

这里必须先做一次需求纠偏。用户要的是**程序**（提高单机产出效率），而不是**评测报告**。但用户同时要求产出与任务 1/2/3 同构的调研成果。这两件事并不矛盾，而是同一问题的两面：

- 若没有量化指标，就无法证明"多部并行"到底有没有真的提效——**提效多少必须能被测量**；
- 若没有赛事评分口径，产出的剧目在投稿时可能因形式问题被直接筛掉——**达标必须能被体检**。

因此本任务的工具包 `ai-drama-evalkit` 与前三份不同：它不是"跑测试集算分"，而是同时覆盖**工程产能**与**作品合规**两条线。

具体拆解用户痛点，得到三个待回答的问题：

1. 一台设备到底能同时跑几部剧？ 上限由什么决定？——由显存，不是由调度算法。
2. 并行之后真的更快吗？快多少？——必须区分"总吞吐"和"首集交付时间"，两者的答案完全相反。
3. 产出的剧目能不能过赛事的门槛？——形式闸门要在提交前自动拦截。

1.3 与任务 1/2/3 的范式差异

这是本报告最重要的方法论判断。前三个任务面对的都是**技术评测型**（technical evaluation）赛事，本任务面对的是**作品评选型**（work judging）赛事。两者的差别不是程度问题，是范式问题：

维度	任务1 TREC / 任务3 IWSLT	本任务 AI 剧目赛事
评测对象	系统输出（run 文件 / 译文）	作品（成片 + 故事陈述）
参考答案	官方 qrels / 官方参考译文	无（没有"标准答案剧"）
评分方式	官方 scorer 自动计算（trec_eval / SacreBLEU）	评委主观打分
结果性质	可复现、可重算	一次性、不可重算
主办方角色	出数据、出 scorer、出 proceedings	出奖金、出评委、出展播渠道
参与成本	提交一次 run 约几小时	产出一部 ≥10 分钟成片约数十机时

结论：本任务不能照抄任务 1 的"官方 scorer"思路。对应的替代方案是——把主观评审过程**结构化**（固定维度、固定权重、固定量表），并把**评委一致性**做成可计算的客观指标（Kendall's W）。这是本任务能拿到的"最硬的客观抓手"。

第二章 分析过程与解决思路

2.1 第一个判断：这个领域没有官方技术评测，不能硬套

接到任务后首先按任务 1 的划线标准去找"AI 视频生成的官方评测竞赛"，结果是明确的否定：

- 学术侧的 VBench、EvalCrafter、FETV、T2VSafetyBench 全部是**研究团队发布的基准 (benchmark)**，没有注册制、没有官方 qrels、没有官方 scorer、没有 proceedings 论文集；
- 工业侧的 Artificial Analysis Video Arena 是**商业榜单**，Elo 制匿名对战，连测试集都不公开；
- 国内赛事（鲸锐、河马杯、腾讯 i 短剧、北京 AIGC、上海提示未来）全部是**作品评选**，评委打分，无技术指标。

唯一擦边的是 WMT 的多模态机器翻译（MMT）任务——但它在 2016、2017 办了两届就停了，这个事实在任务 3 报告里已经记录过。

处理方式：不掩盖这个缺口，在报告里明确写"不存在"，然后把工作重心转向两条真正有价值的线——（a）把作品评选的评审口径做成可复现工具；（b）把用户真正的产能痛点做成可量化模型。

2.2 第二个判断：用户要的是产能，产能必须能反解

"一台设备同时出多部剧"这句话在工程上其实含糊。它至少可以指三件事：

1. **同时并行数：**同一时刻有几部剧在生成——受显存硬约束；
2. **单位时间交付数：**一天能出几部——受单镜头耗时与废片率约束；
3. **首部交付时间：**第一集什么时候能看到——受调度顺序约束。

这三件事的最优解**不是同一个调度策略**。所以工具必须能分别报告这三个数，而不是给一个笼统的"提升了 X%"。

`plan_production.py` 的核心设计就是把这三件事分开报，并且显式区分"显存决定的同时并行上限"与"时间决定的累计交付数"——前者是硬顶，后者可以靠拉长工期无限累加。

2.3 第三个判断：并发的真实收益在"首集延迟"，不在"总吞吐"

`throughput_sim.py` 的实测结果给出了一个反直觉但关键的结论：

- 相对串行，流水线策略总吞吐只提升约 9%；
- 但**首集交付时间缩短约 74%**。

原因是：GPU 是串行资源，镜头总量不变时总 GPU 工时不变，并发只能让不同剧的镜头交错、把换剧开销藏进 CPU 阶段，无法凭空减少总工时。但**谁先完工**是可以靠调度大幅改变的。

这个结论直接回答了用户的业务诉求：**如果你的 KPI 是"一天出多少集"，并发帮不了多少，得去降单镜头耗时；如果你的 KPI 是"多久能交第一集"，并发是立竿见影的杠杆。**

2.4 第四个判断：大赛评分口径要做成工具，而不是抄一遍规则

鲸锐大赛公布的四维评审口径（选题创意 / 叙事技巧 / 视听语言 / 社会价值）如果只是"抄进报告"，价值为零。做成工具后能多拿到三样东西：

- 1. **Kendall's W** —— 量化"这场比赛评得到底准不准"。这是唯一能把主观评审拉到客观地面的指标；
- 2. **留一法稳定性检验** —— 去掉任一位评委，冠军会不会变。变了说明排名脆弱；
- 3. **硬门槛闸门** —— ≥ 10 分钟、 ≥ 1000 字、原创性，这三项不满足直接淘汰，不看分数，必须做成提交前自动校验。

2.5 执行路径总览

```
需求：一台设备多部剧
├── 调研（第三章）—— 学术基准 / 国内赛事 / 鲸锐大赛深度解析
├── 技术路线（第四章）—— 三代生成模型 / 一致性难题 / 单机多剧调度
├── 数据集（第五章）—— 学术基准集 / 赛事作品集 / 自建产能数据
├── 指标（第六章）—— 生成质量 / 评审维度 / 产能工程指标
├── 工具（第七章）—— ai-drama-evalkit
│   ├── throughput_sim.py    5 策略离散事件模拟
│   ├── plan_production.py   产能反解（同时数 vs 累计交付数）
│   ├── rubric_score.py      四维评分 + Kendall's W + 留一法
│   └── check_deliverable.py 提交前体检（闸门/规格/字幕）
```

第三章 国内外评测的前世今生

3.1 学术侧：从"能不能生成"到"生成得好不好"

AI 视频生成的评测比 NLP/IR 晚了二十多年，走过的路径却惊人相似——都是先解决"有没有"，再解决"好不好"，最后解决"怎么测"。

第一代（2016–2021）：指标借用期。 早期视频生成（VGAN、MoCoGAN、DVD-GAN）直接借用图像生成的 Inception Score (IS) 和 Frechet Inception Distance (FID)。问题在于 FID 只比较单帧分布，完全不看时间维度——一段画面精美但内容乱跳的视频，FID 可能很好看。随后出现 FVD (Frechet Video Distance)，把 I3D 特征接入 FID 框架，才算第一次有了"视频级"的自动指标。

第二代（2022–2023）：文本对齐期。 CLIP 横空出世后，CLIPSIM / CLIP-temp 成为标配，解决"生成的内容跟提示词对不对得上"。这一代的代表工作是 Make-A-Video、Imagen Video、Phenaki。评测开始区分"视频质量"与"文本一致性"两条线。

第三代（2023–至今）：多维拆解期。 随着 Sora、Kling、即梦等产品化，单一分数彻底不够用了。评测转向**多维度拆解 + 人类偏好对齐**。VBench 是这个阶段的标志性工作：它把"视频生成质量"拆成 16 个可自动测量的维度，并对每个维度单独做人类偏好标注来验证自动指标的可信度。

3.2 学术基准集一览

按任务 1 的划线标准，下面这些**都不是官方评测竞赛**，而是研究团队发布的基准。列在这里是为了说明"学术界目前最权威的尺子是什么"，但必须标明它们不具备主办机制。

基准	提出方	规模	维度	性质
VBench	清华大学	1,746 提示词, 24 个子类别	16 个维度 (分 8 大类)	学术基准, 有 leaderboard
EvalCrafter	新加坡国立等	700 提示词, 2,500 视频	4 个元类: 视觉、内容、运动、质量	学术基准
FETV	复旦大学等	619 提示词	细粒度文本-视频对齐	学术基准
T2VSafetyBench	中科院等	4,400 提示词, 17,600 视频	12 个安全类别	安全专项基准
VIDEOPHY	加州大学等	—	物理常识符合性	学术基准
TC-Bench	—	—	时间一致性	学术基准
VideoFC	—	—	事实一致性	学术基准
DrawBench	Imagen 团队	200 提示词	图文对齐 (图像侧)	学术基准

VBench 的 16 个维度 (这是目前最被认可的拆解框架)：

大类	具体维度
时间质量	主体一致性、背景一致性、时间闪烁、运动平滑度
帧内质量	动态程度、美学质量、成像质量、目标类别
语义对齐	外观风格、人类动作、颜色、空间关系、场景
其他	多目标、综合得分

VBench 的方法论价值高于它的分数价值：**它证明"自动指标必须与人类偏好做相关性验证"**。这一点在本报告第六章被直接沿用——产能指标也必须与用户的实际观感（能不能过审、观众买不买账）挂钩，否则就是自娱自乐。

3.3 商业侧：Artificial Analysis Video Arena

目前工业界最接近"竞技评测"的是 Artificial Analysis 的 Video Arena：Elo 制、匿名两两对战、人类投票。它解决了学术基准的僵化问题（提示词被反复刷分），但引入了新问题：

- 测试集不公开，无法复现；
- Elo 分受参与人群偏好影响，不等于客观质量；
- 无主办机制、无 proceedings。

判据结论：按任务 1 的划线标准，它不是官方评测竞赛。但它是目前**模型选型**最快的参考——如果你的剧目要选底模，看 Arena 比看论文快。

3.4 国内赛事：全部是作品评选型

这是本任务真正要参加的战场。国内目前有影响力的 AIGC 短剧赛事：

赛事	主办	奖金池	时间	特点
鲸锐 AI 创作大赛	虎鲸文娱（优酷）	1000 万元	2026-09-17 启动， 截稿 11-22	国内首个千万级 AI 视频赛事，265 个获奖名额
腾讯视频 AI 创作大赛·i 短剧	腾讯视频	120 万元	2025-10-24	平台导向，重播出转化
河马杯微短剧创作大赛	第 20 届中国好创意大赛 AIGC 赛道	赛事制	马栏山	高校体系背书，竖屏规格
AIGC 网络微短剧/微电影大赛	北京市，广电总局指导	赛事制	—	92 部作品入围，10 部获奖，官方背景最强
上海国际"提示未来"AIGC 短片大赛	上海市	41 万元	已办至第三届	国际化程度较高

共同特征（这是范式判断的依据）：

- 1. 无官方测试集 —— 参赛者自带作品，没有统一题目；
- 2. 无官方 scorer —— 评委打分，人工汇总；
- 3. 无 proceedings —— 不要求技术报告，只要成片 + 陈述；
- 4. 有硬门槛 —— 时长、字数、原创性，不满足直接淘汰；
- 5. 有展播/签约激励 —— 赛事的实质奖励不只是现金，还有平台分发与人才签约。

产业背景（决定这些赛事为什么在 2025–2026 集中爆发）：

- 2024 年中国微短剧市场规模 **504.4 亿元**，同比增长 34.9%，**首次超过电影票房**；
- 微短剧用户 **5.76 亿**，占网民 52.4%；
- 北京一地产值 336.2 亿元，约占全国三分之二；
- 行业预计 2027 年市场规模达 1000 亿元（白皮书口径 856.5 亿元，美元口径约 140 亿）；
- **AIGC 可降本 30% 以上**；传统微短剧拍摄周期 7–10 天、成本 30–50 万元。

这组数字说明了用户痛点的商业价值：把单机产能提上去，直接对应成本结构的改善。

3.5 鲸锐大赛深度解析

用户要求深入研究的公众号文章，核心内容如下。

赛事定位：虎鲸文娱（原阿里文娱，旗下优酷）于 2026 年 9 月 17 日启动，宣称是国内首个奖金规模达千万元级的 AI 视频创作赛事。

奖项结构（合计 265 个获奖名额，这是它区别于其他赛事的最大特点——不是少数头部通吃，而是广覆盖）：

奖项	名额	单笔奖金	小计
鲸锐人才奖	1	200 万	200 万
最佳原创 IP 奖	4	50 万	200 万
单项奖（创意表达 / 叙事结构 / 视觉效果 / 角色塑造）	4 类 × 5 名	10 万	200 万
新锐创作者奖	40	5 万	200 万
潜力创作者奖	200	1 万	200 万
合计	265	—	1000 万

硬性要求（三项闸门，不满足直接淘汰）：

- 1. 成片时长 ≥ 10 分钟；
- 2. 故事陈述 ≥ 1000 字；
- 3. 原创，**非既有 IP** 改编。
- 4. 工具与题材不限（不绑定特定平台）。

评审四维口径：

维度	权重（本工具默认等权）	内涵
选题创意	25%	题材开掘、世界观设定、原创性
叙事技巧	25%	结构完整、节奏控制、人物弧光、情节推进效率
视听语言	25%	画面质量、镜头调度、声音设计、AI 生成痕迹控制
社会价值	25%	议题公共性、情感共鸣、价值导向

赛程：前 25 名进入线下提案（pitch）环节；截稿 2026 年 11 月 22 日。

生态协作：优酷负责线上展播、大麦娱乐负责线下、TapNow 作为独家 AIGC 生态伙伴。

人才计划（这是比奖金更长期的部分）：大师面对面、创作沙龙、作品展映。

前身脉络（说明这不是孤立事件，而是虎鲸文娱连续三年的人才布局）：

- **春苗编剧计划**（2024）：3000+ 创作者参与，落地 20 部剧本；
- **海纳国际青年导演计划**；
- **虎鲸超越班**。

对本项目最直接的影响：四维口径 + 三项闸门，已经直接写进 `rubric_score.py` 与 `check_deliverable.py` 的默认量表。用户若要投这个赛，提交前跑一次体检即可知道会不会被形式问题筛掉。

3.6 演进规律：为什么 AI 视频没有 TREC

把第三章的事实串起来，可以回答一个更根本的问题：同样都是"评测"，为什么 IR 有 TREC、MT 有 WMT/IWSLT，而 AI 视频没有对应的官方技术评测？

三个结构性原因：

1. **没有可枚举的"正确输出"**。检索的正确结果是文档 ID，翻译的正确结果是参考译文——都可以枚举并做成 qrels。视频的"正确输出"是连续像素流，无法枚举，只能做偏好判断。Cranfield 范式在这里失效。
2. **生成成本过高，无法大规模提交**。TREC 一个 run 文件几十 MB，参赛队可以提交多次；一部 ≥ 10 分钟的 AI 剧目需要数十机时，参赛者一年只能交几部。样本量支撑不起统计显著性检验。
3. **产业形态是"作品"而非"系统"**。检索和翻译的买家是做系统的工程师，需要可比的技术指标；AI 视频的买家是内容平台，需要的是能播的片子。需求方决定了评测形态。

推论（也是本任务的定位依据）：在可预见的未来，AI 剧目领域的"评测"只会以**作品评选**形式存在。因此本任务的工具包不追求做一个"AI 剧目的 trec_eval"，而是做**产能量化 + 评审结构化 + 提交体检**这三件真正用得上的事。

第四章 技术路线演进

4.1 三代生成技术路线

代际	代表	核心机制	对剧目制作的适用性
第一代	VGAN、MoCoGAN、DVD-GAN	GAN + 隐空间解耦	分辨率低、时长短，不可用于成片
第二代	Make-A-Video、Imagen Video、Phenaki、AnimateDiff	潜空间扩散（LDM）	可出 4-16 秒镜头，可控性提升，成为当前主力
第三代	Sora、Kling、即梦、可灵	DiT（Diffusion Transformer）+ 时空 patch	分钟级连贯，具备成片能力

对本项目的技术选型判断：第二代（SDXL + AnimateDiff / IP-Adapter 一类的 ComfyUI 流水线）仍是**本地可控部署**的主力；第三代闭源模型质量更高但只能通过 API，与"基于我们设备"的前提冲突。

4.2 一致性：剧目制作真正的技术瓶颈

单张图好看不等于能成剧。剧目级制作的三个一致性难题：


- **角色一致性**：同一角色跨镜头必须可辨认。主流做法是角色 LoRA + 参考图（IP-Adapter / InstantID）+ 面部修复。这也是显存工作集里 `vram_lora_gb` 与 `vram_refimg_cache_gb` 两项的来源。
- **场景/风格一致性**：靠风格 LoRA、统一色卡、统一后处理 LUT。
- **时间一致性**：镜头内部的运动平滑与不闪烁，以及镜头之间的叙事连贯。

工程含义：一致性手段全部需要"常驻显存"的角色/风格资源。这正是单机多剧并行时显存吃紧的根源——每多一部剧，就要多常驻一套 LoRA 与参考图缓存。**并行度与一致性成本是直接冲突的。**

4.3 单机多剧的调度路线（本任务的核心工程方案）

用户说"用即梦一类的软件，一台设备只能产出一部剧"——这是**软件层面的限制**，不是硬件层面的限制。商业 SaaS 的界面是单任务串行的，但底层 GPU 完全可以跑多实例。

推荐架构：单卡单实例 + 中央调度器



为什么必须"单卡单实例"：RTX 4090 24GB **没有 NVLink**，多卡之间没有高速互联，4 张卡的 96GB 不是一块 96GB，而是四块互不相通的 24GB。把一个 ComfyUI 实例塞多卡，ComfyUI 默认也不会做跨卡模型切分，反而会因为数据搬运变慢。所以正确做法是**每卡一个独立进程**，由外部调度器分发。

关键参数与优化手段：

优化项	手段	影响的参数
显存常驻	ComfyUI <code>--highvram</code> / <code>--medvram</code> / <code>--lowvram</code>	<code>vram_activation_gb</code>
精度	<code>--fp16-unet</code> 、 <code>--bf16-vae</code>	<code>vram_base_model_gb</code>
注意力	<code>--xformers</code>	<code>t_video_s</code>
缓存	<code>--cache-lru</code>	<code>t_ref_img_s</code> 、 <code>switch_cost_s</code>
显存回收	<code>torch.cuda.empty_cache()</code>	<code>gpu_util</code>
换剧开销	LoRA/参考图按剧做缓存池，同剧镜头连续排产	<code>switch_cost_s</code>
CPU 重叠	TTS / 合流与 GPU 推理并行	<code>cpu_overlap</code>

4.4 推荐技术路线

对"基于现有设备、高效产出多部剧目"这个目标，给出的路线是分三步走，**每一步都有可测量的验收标准**：

第一步：先测基线（1-2 天）。 用你自己的设备跑 `plan_production.py --dump-config` 导出参数模板，回填实测的 `t_video_s`、废片率、显存占用。在此之前任何"能跑几部剧"的结论都是猜的。

第二步：改调度（3-5 天）。 部署单卡单实例 + 调度器，把同剧镜头连续排产。验收标准：`switch_cost_s` 占比降到 5% 以内。

第三步：改杠杆（持续）。 当并行度被显存钉死之后，唯一还能提速的是降 `t_video_s`（更快的模型 / 量化 / 蒸馏）与降 `retry_rate`（更好的提示词模板与后处理）。验收标准：单镜头 GPU 工时下降。

第五章 评测数据集

5.1 学术基准集（用于底模选型）

见 3.2 表格。使用建议：**只用于选型，不用于验收**。原因是这些基准的提示词是公开的，刷分严重，且分布与你实际要做的剧目题材未必一致。

5.2 赛事作品集（用于风格与评委偏好分析）

来源	可用性	说明
鲸锐大赛入围/获奖作品	截稿后公开	2026-11-22 截稿，届时是最好的"评委偏好"样本
北京 AIGC 大赛 92 部入围 / 10 部获奖	部分公开	官方背景强，题材口径可作为合规参照
腾讯 i 短剧获奖作品	平台内	重播出转化，商业导向样本
河马杯获奖作品	公开	竖屏规格样本

用法：把这批作品当作"小样本 qrels"——用 `rubric_score.py` 按四维口径自己打一遍分，再与官方获奖名单比对，可以反推评委的隐性偏好权重（例如社会价值是否实际被加权更高）。这相当于在没有官方 qrels 的情况下，自建一个校准集。

5.3 自建产能数据集（本任务真正要建的数据）

这是用户自己能拿到、且学术界没有的数据：**单机多剧的生产日志**。建议每张卡、每个实例记录：

字段	含义
<code>ts_start / ts_end</code>	镜头开始/结束时间戳
<code>drama_id / episode_id / shot_id</code>	归属
<code>gpu_id / instance_port</code>	执行位置

字段	含义
phase	ref_img / video / tts / mux
retry_count	该镜头重做次数
vram_peak_gb	峰值显存
switch_flag	是否与上一镜头不同剧（换剧开销归因）
status	success / failed

有了这份日志，`plan_production.py` 与 `throughput_sim.py` 里的所有示例值都能被**真实数据**替换，结论才从"示例"变成"你家的实测"。这是两份工具唯一无法替你完成的一步。

5.4 数据规范

- 所有日志 UTF-8，时间戳统一 ISO 8601；
- 成片封装 MP4（H.264/H.265），音轨 AAC ≥96 kbps；
- 字幕 SRT，UTF-8 **无 BOM**（BOM 会让部分解析器把首条字幕当成乱码）；
- 故事陈述独立 txt/md，便于 `check_deliverable.py` 计字。

第六章 评价指标

6.1 生成质量维度（VBench 框架，16 维）

见 3.2。本报告不重复展开，只强调一个使用原则：**不要看总分**。总分会把"动态程度高"和"主体一致性差"相互抵消，而这两者对你的剧目是完全不同的后果。分维度看，并且只盯与你题材相关的那几个（剧情向盯主体一致性、时间闪烁；视觉向盯美学质量、成像质量）。

6.2 赛事评审维度（鲸锐四维）

维度	权重	量表	本报告工具支持
选题创意	25%	1-10	<code>rubric_score.py</code>
叙事技巧	25%	1-10	同上
视听语言	25%	1-10	同上
社会价值	25%	1-10	同上

配套的两个客观指标（本报告新增，赛事官方并未提供）：

- **Kendall's W**：评委在单一维度上的排序一致性， $W \in [0,1]$ 。判读阈值见下表。
- **留一法翻转率**：去掉任一位评委后前三名是否变化。

W 区间	判读
≥ 0.8	高度一致，排序可靠
0.6–0.8	基本一致，分数差需谨慎
0.4–0.6	中等一致，建议加评委或开校准会
0.2–0.4	弱一致，量表需细化到锚点案例
< 0.2	几乎无一致，不宜作为唯一裁决依据

经验参照：TREC 池化人工判定的 κ 通常在 0.6–0.8。AIGC 作品评选若 $W < 0.4$ ，排名基本等同于抽签——这时候"没获奖"不代表作品差，只代表评审噪声大。

6.3 产能与工程指标（本项目定义）

这是本任务真正新增的部分。定义如下：

指标	定义	为什么需要
同时并行数 <code>concurrent_dramas</code>	同一时刻在生成的剧目数	受显存硬顶，用户问的"同时出几部"就是它
累计交付数 <code>delivered_per_day</code>	单位时间完成的剧目数	受时间约束，可随工期线性累加
首集交付时间 <code>first_ep_hours</code>	从开工到第一部剧首集完成的墙钟时间	并发的真实收益所在
GPU 利用率 <code>gpu_util</code>	GPU 忙时 / 总墙钟	低于 60% 说明调度或 IO 有瓶颈
切换开销占比 <code>switch_overhead</code>	换剧耗时 / 总墙钟	高于 20% 说明排产粒度太细
废片率 <code>retry_rate</code>	重做镜头 / 总镜头	AI 生成必须有，不计入会严重低估工期
单镜头摊薄工期 <code>per_shot_minutes</code>	总工期 / 总镜头数	判断并行是否饱和的判据

饱和判据：每多并行一部剧，单镜头摊薄工时的下降幅度 $< 3\%$ 即视为饱和。饱和之后再加并行只是在排队。

6.4 一致性指标

- **角色一致性：**跨镜头角色 embedding 余弦相似度均值（可用 CLIP / ArcFace 抽特征自算）；
- **风格一致性：**帧级美学分数方差（方差越小越稳）；
- **时间闪烁：**相邻帧 CLIP 特征距离的标准差。

这三项学术界有对应实现，但**没有官方标准**——本报告只给出可自算的口径，不宣称权威。

6.5 三个必须避开的陷阱

陷阱一：把"并行数"当成"产能"。 并行 3 部和并行 2 部，总吞吐可能完全一样（超出槽位的部分在排队）。报告产能时必须同时给出"同时并行数"和"累计交付数"两个数，只报一个必被误导。

陷阱二：不计废片率。 AI 生成的废片率轻松达到 15%–30%。工期估算若不计入，实际会超出预期三分之一以上。本项目所有公式都显式含 `(1 + retry_rate)`。

陷阱三：把主观评审分数当客观指标用。 鲸锐四维分数是评委的主观判断，不同场次不可比、不同评委不可比。只有 **Kendall's W** 和**留一法翻转率是客观的**——它们衡量的是"评审过程"而不是"作品"。要证明作品好，靠的是一致性指标；要质疑评审结果，靠的也是一致性指标。

第七章 评测工具

7.1 学术界与工业界工具

工具	用途	性质
VBench	16 维自动评测	学术基准，开源
EvalCrafter	多维度视频质量	学术基准
T2VSafetyBench	安全合规	学术基准
Artificial Analysis Video Arena	Elo 排行	商业榜单
ComfyUI	生成流水线	工程框架
ffprobe	成片技术规格探测	通用工具

7.2 本任务交付的工具包 `ai-drama-evalkit`

ai-drama-evalkit/ └─ tools/ ├─ throughput_sim.py 5 策略离散事件模拟：串行/FIFO/轮转/按剧批量/流水线 ├─ plan_production.py 产能反解：显存墙 + 时间墙 + 切换墙 + 饱和拐点 ├─ rubric_score.py 四维评分 + Kendall's W + 留一法 + 硬门槛 └─ check_deliverable.py 提交前体检：资格闸门/技术规格/字幕合规	
---	--

四个工具的职责分工（刻意做成互不重叠）：

工具	回答的问题	输入	输出
<code>throughput_sim.py</code>	给定 N 部剧，哪种调度最快？	镜头耗时、切换开销、废片率	5 策略对比表
<code>plan_production.py</code>	我的设备最多能同时跑几部？几天能交几部？	设备规格 + 工期	显存墙/时间墙/饱和点/反解
<code>rubric_score.py</code>	这场比赛评得准不准？我的作品排第几？	评委打分 CSV	W 值、排名、留一法
<code>check_deliverable.py</code>	我的作品会不会被形式问题直接筛掉？	成片/字幕/陈述	阻塞项清单

7.3 使用与依赖

四个脚本零**第三方依赖**，Python 3 标准库即可运行（实测 Python 3.12 通过）。
`check_deliverable.py` 的 `ffprobe` 是可选增强：存在则真实探测分辨率/帧率/音轨，不存在则退回声明值校验并明确标注"未实测"，不会把声明值伪装成实测值。

```
python3.12 tools/throughput_sim.py
python3.12 tools/plan_production.py --dramas 3 --deadline-days 3
python3.12 tools/plan_production.py --dump-config my.json # 导出参数模板
python3.12 tools/rubric_score.py --demo
python3.12 tools/rubric_score.py --scores s.csv --rubric jingrui --trim 0.1
python3.12 tools/check_deliverable.py --demo --original
python3.12 tools/check_deliverable.py --video a.mp4 --srt a.srt \
    --statement story.txt --rule jingrui --original
```

第八章 实证：工具包实测结果

所有结果在本机（Ubuntu 22.04 / Python 3.12）实跑得出，参数均为**示例值**，未用用户设备的真实数据标定。这一点必须反复强调：**数字的意义在于演示模型用法，不在于给出你的设备结论。**

8.1 调度策略对比（默认配置：2 卡 × 24GB，3 部剧）

策略	总完工 h	GPU 利用率	切换次数	切换开销	首集交付 h	单剧完成 h	镜头/小时
serial（串行）	9.01	86.7%	2	0.1%	3.32	6.01	66.6
fifo	12.32	63.4%	599	27.0%	1.25	12.30	48.7
round_robin	12.32	63.4%	599	27.0%	1.25	12.30	48.7
batch_by_drama	9.41	83.0%	74	4.4%	0.97	9.29	63.8
pipeline（流水线）	8.24	94.8%	74	5.0%	0.86	8.14	72.8

判读：

- 流水线吞吐最优（72.8 镜头/小时），但相对串行**只提升 9.3%**；
- 流水线首集交付 0.86 h，相对串行（3.32 h）**缩短 74.1%**；
- FIFO 与轮转的切换开销高达 27.0%，是典型的"排产粒度太细"反例——每镜头换一次剧，把时间全花在换 LoRA 上；
- 按剧批量把切换次数从 599 降到 74，开销降到 4.4%，这是**最容易被忽视却最有效的一招**。

结论：并发的价值在交付延迟，不在总吞吐。想提高总吞吐，唯一杠杆是降 `t_video_s`。

8.2 产能反解（2 卡 × 24GB，3 天工期）

显存墙：

单卡显存 24 GB（无 NVLink，多卡不共享显存）
扣除共享 1.8 GB + 预留 2.0 GB 后可用：20.20 GB
单部剧工作集：12.60 GB = 底模 6.5 + LoRA 0.4 + 参考图 1.2 + 激活 3.5
→ 单卡可常驻剧目数：1 部
→ 整机槽位数（2 卡）：2 个

时间墙与饱和点：

并行剧数	并发槽位	排队	镜头数	GPU 工时 h	工期 h	首集 h	镜头/时
1	2	0	60	2.65	3.26	3.29	18.4
2	2	0	120	5.31	3.30	3.29	36.4
3	2	1	180	7.96	4.96	3.29	36.3
4	2	2	240	10.62	6.61	3.29	36.3

关键判读：

- 并行 1→2 部，单镜头摊薄工期从 3.26 分钟降到 1.65 分钟（+97.7%）；
- 并行 2→3 部，-0.1%，已饱和；
- 饱和点（2 部）正好等于显存槽位数——这说明拐点由显存决定，不是由调度算法决定；
- 3 天工期内累计可交付 36 部，但同时并行上限仍是 2 部，36 部是靠分 18 批跑完的。

这两条数字合起来，就是"一台设备能不能同时出多部剧"的完整答案：能，但同时数由显存钉死在槽位数；总交付数由单镜头耗时决定，可以靠时间堆。

8.3 评委一致性与排名稳定性

演示数据（5 评委 × 8 作品，确定性构造）：

维度	Kendall's W	判读
选题创意	0.605	基本一致
叙事技巧	0.481	中等一致
视听语言	0.605	基本一致
社会价值	0.418	中等一致
四维平均	0.528	中等，建议开校准会

留一法检验（去掉任一位评委，看前三名是否变化）：

去掉 J1：前三 [W3, W7, W5] 变化
去掉 J2：前三 [W3, W7, W5] 变化
去掉 J3：前三 [W3, W7, W1] 不变

去掉 J4：前三 [W3, W5, W7] 变化
去掉 J5：前三 [W3, W7, W1] 不变
→ 2/5 次留一法检验导致前三名变化

判读：冠军（W3）稳定，但亚军/季军不稳。这正是"W 在 0.5 左右"时的典型表现——**头部可信，边缘名次不可信**。若赛事只在头部颁奖，W=0.5 尚可接受；若像鲸锐这样设 265 个名额、需要细分到边缘名次，W=0.5 远远不够，必须细化量表锚点或增加评委。

8.4 提交体检的证伪测试

`check_deliverable.py --demo` 故意造了一段含两处硬伤的字幕（一行超长导致 CPL 超标、一条时间轴重叠），工具如实报出：

x 阻塞项 3 条：

- 字幕：CPS 超标 1 条（阈值 9，实测峰值 24.0）
- 字幕：CPL 超标 1 条（阈值 16，实测峰值 24）
- 字幕：时间轴重叠 1 条

！ 未校验 2 条：故事陈述未提供、视频未提供

✓ 通过 2 条：原创性已声明、时长 12.00 分钟（声明值）

判定：不予提交

为什么要做这个证伪测试：一个只会说"通过"的体检工具是没有价值的。必须先证明它能抓到错，才能相信它报的"通过"。这与任务 1 `check_format.py` 的做法一致。

8.5 开发过程中真实踩到并修复的坑

坑	现象	修复
f-string 内嵌同类引号	<code>rubric_score.py</code> 语法错误，无法启动	改用中文书名号「」，f-string 外拼接
反解结论自相矛盾	报"可行 36 部"但"显存硬顶 2 部"，读者必然困惑	拆成两个数：同时并行上限 vs 累计交付数，并说明分批逻辑
边际收益拐点表述不准	原写"超过 3 部衰减"，实际拐点是槽位数 2	改为"超过 2 部"，并点明拐点由显存决定
演示数据过于理想	初版 W=0.978，不真实，失去演示价值	加大评委抖动至 ±1.5 分（真实评审会量级），W 落到 0.528
总分公式重复计算	<code>total_wall_s</code> 写了两遍，第一遍是废逻辑	保留正确的一行

第九章 结论与建议

9.1 核心结论

1. **AI 剧目领域不存在官方技术评测。** 这是事实，不是调研不到位。学术侧只有研究团队发布的基准（VBench / EvalCrafter / FETV / T2VSafetyBench），国内赛事全部是作品评选型。根本原因在于视频的"正确输出"无法枚举，Cranfield 范式在此失效。
2. **国内赛事在 2025–2026 集中爆发，底层驱动是微短剧产业。** 2024 年市场规模 504.4 亿元（首超电影票房），用户 5.76 亿，AIGC 可降本 30% 以上。鲸锐大赛 1000 万奖金、265 个名额，是目前规格最高的入口。
3. **"一台设备同时出多部剧"的上限由显存决定，不是调度算法。** 实测饱和点（2 部）正好等于显存槽位数。RTX 4090 无 NVLink，多卡不共享显存，这是硬约束。
4. **并发的真实收益是首集交付时间（-74%），不是总吞吐（+9%）。** 这两个数必须分开报。若 KPI 是"一天出多少集"，并发帮不上忙，得去降单镜头耗时。
5. **最容易被忽视却最有效的一招是按剧批量排产。** 切换次数从 599 降到 74，切换开销从 27.0% 降到 4.4%，比换调度策略的收益大得多。
6. **主观评审唯一能拉到客观地面的抓手是 Kendall's W 与留一法。** 鲸锐设 265 个名额意味着要细分到边缘名次，这对评审一致性提出了远高于头部颁奖的要求。

9.2 给你的落地建议

立即可做（本周）

1. 跑 `python3.12 tools/plan_production.py --dump-config my.json`，把你的 GPU 型号、卡数、实测单镜头耗时、废片率填进去。**在此之前任何"能跑几部"的结论都是猜的。**
2. 跑 `check_deliverable.py` 体检现有素材，先确认不会因为时长/字数/原创性被直接筛掉。
3. 若要投鲸锐，注意截稿 2026 年 11 月 22 日，且需要 ≥ 10 分钟成片 + ≥ 1000 字故事陈述。

短期（两周内）

1. 部署单卡单实例 + Python 调度器（ComfyUI 端口 8188/8189/...），先把 `switch_cost_s` 占比压到 5% 以内。
2. 按 5.3 的字段开始记录生产日志——这是唯一能让工具结论从"示例"变成"你家的实测"的一步。

中期（一个月）

1. 当并行度被显存钉死之后，转攻 `t_video_s`：更快的底模、fp8/GGUF 量化、蒸馏小模型，或 LoRA 合并。这才是吞吐的真正杠杆。
2. 若投赛事，用 `rubric_score.py` 自建一个小规模校准集（自己按四维打一遍获奖作品），反推评委的隐性权重。

9.3 待办与风险

项	状态	说明
参数用真实设备标定	待你提供	当前所有数字是示例值，未经你的设备验证

项	状态	说明
生产日志规范落地	待办	见 5.3，需在你的流水线里埋点
鲸锐获奖作品样本	待截稿后	2026-11-22 之后的公开作品可做偏好分析
一致性自动指标实现	未做	角色/风格/闪烁三项只给了口径，未写代码
多机扩展	未涉及	本报告只覆盖单机多卡

风险提示：

- **工具结论的参数依赖性**。四个工具的全部结论都建立在输入参数上。参数错了，结论必然错，且工具不会报错。这是最大的使用风险。
- **赛事规则可能变更**。鲸锐四维口径与三项闸门来自 2026-09-17 的公开信息，投稿前请以官方最新公告为准。
- **不要指望"加并发"解决产能问题**。本报告实测已证明：超出显存槽位之后，加并行只是在排队。

本报告与 `ai-drama-evalkit` 工具包配套。所有示例数值均可被你的实测数据替换，替换方式见各工具的 `--dump-config` / `--config`。