

任务1调研报告

官方评测竞赛的检索数据集与评价工具调研

报告日期：2026 年 9 月 23 日

任务编号：任务 1

官方评测竞赛的检索数据集与评价工具调研

报告日期：2026 年 9 月 23 日 任务编号：任务 1 任务目标：调研官方公开举办的评测竞赛所提供的检索评测数据集与评价工具，形成可执行的跑通清单 交付物： `/workspace/trec-eval-kit/`（文档 + 三个已验证脚本 + 真实官方数据）

第一章 任务概述

1.1 提示词回溯

本次任务由用户当日上午连续三次提问逐步收敛而成，原文如下。

提示词一（需求萌发）

请问搜索引擎的评测数据集

提示词二（边界收敛）

要求官方公开举办的评测竞赛的数据集与评价工具

提示词三（执行排序）

两个都要，不过一个一个来，先完成1，再做2

提示词四（本报告成因）

请为1和2两项任务分别撰写名为"任务1调研报告.pdf"与"任务2调研报告.pdf"的文档报告，报告中，请将今天早上与任务相关的所有我发给你的提示词，以及你的深度思考过程，及如何解决任务的思路，以及重点描述任务涉及的国内外评测竞赛的前世今生，技术路线，评价数据集，评测指标与评测工具等内容

1.2 需求界定

三次提问构成一条清晰的收敛链：

轮次	用户输入	关键增量	对方案的影响
一	"搜索引擎的评测数据集"	宽泛咨询	需先做范围界定，不能上来就列清单
二	"官方公开举办的评测竞赛"	限定为 Evaluation Campaign / Shared Task	排除 BEIR、MTEB、C-MTEB 一类民间 benchmark 集合
三	"先完成1，再做2"	串行执行约束	任务1（跑通清单）先交付，任务2（自建方案）后交付

第二轮的限定词是整个任务的分水岭。它把"有哪些数据可以测"变成了"哪些机构有权发布标准答案"。

第二章 分析过程与解决思路

2.1 第一个判断：先划清"官方"与"民间"的界线

拿到"评测数据集"这个宽泛提问时，最直接的回答是列 BEIR、MTEB、C-MTEB 这类常见榜单。但这条路是错的——用户第二轮明确要求"官方公开举办的评测竞赛"，说明他要的是可引用、可对甲方/审稿人交代的权威来源。

两者的本质差别不在数据质量，而在是否有组织机制：

维度	官方评测竞赛	民间 benchmark 集合
组织方	NIST、NII、CLEF 协会等常设机构	研究者自发整理
参与方式	注册参赛、提交 run	无需注册，直接下载
标准答案	组委会发布 qrels	沿用上游数据集自带标注
评分程序	官方 scorer，唯一权威实现	各家自行实现，边界处理不一
成果形式	官方 proceedings / overview 论文	排行榜
可引用性	可写"参加 TREC 2025 RAG"	只能写"在公开 benchmark 上评测"

这个判断直接决定了报告第一章的存在——它帮用户避开一个在论文中会被审稿人直接点破的表述错误。

2.2 第二个判断：先核实，再动笔

信息检索评测领域的数据集名称、规模、MD5、赛道设置在近两年变化很快（TREC 每年换 track，MS MARCO 语料版本迭代到 V2.1）。凭记忆写清单风险极高，尤其在用户要拿去做正式材料时。

因此执行顺序定为：**联网核实** → **下载真实数据** → **本地跑通** → **再写文档**。共发起六次检索，覆盖 BEIR 现状、中文评测集、TREC 2025 赛道设置、NTCIR/CLEF 官方工具、TREC DL 数据口径、UMBRELA 自动判定。

核实过程中修正了三处初始偏差：

- 1. **TREC 2025 的赛道与我预期不同**——实际为 AVS、BioGen、DRAGUN、iKAT、Million LLM、Product Search、RAG、RAGTIME、ToT、VQA 十个，其中 RAG 是第二届。
- 2. **TREC 2025 RAG 的查询形态变了**——从 2024 年的短关键词改为多句叙述型 narrative，并按"文档回答了多少个子叙述"打 0-4 分。
- 3. **评测工具链的安装条件受限**——沙箱访问 GitHub 的 TLS 握手失败，官方 `trec_eval` 无法克隆编译。

2.3 第三个判断：用实证代替描述

一份"跑通清单"如果没跑过，价值接近于零。因此决定**不下载 28 GB 语料**（无必要且耗时），而是下载体积很小但真实权威的官方 `qrels` 与 `topics`，在真实数据上端到端验证工具链。

设计三组对照实验，让结论自带证据：

实验	构造方式	预期	实际	证明什么
Oracle	按相关性降序的完美排序	nDCG@10 = 1.0	1.0000	工具链与口径配置正确
Shuffle	随机打乱	明显低于 1.0	0.4034	指标具备区分度
DocLevel	去掉 #段号 退化为文档级	恒为 0	0.0000	粒度错配是致命且静默的坑

第三组尤其重要：它把一个"说起来像常识"的警告变成了有数值支撑的结论，并且直接催生了校验脚本中的 [D] 检查项。

2.4 第四个判断：工具链受阻时的等价替代

官方 `trec_eval` 编译失败后，有两条路：放弃验证、或找等价实现。选择后者——`pytrec_eval-terrier` 编译的是 NIST 同一份 C 源码，Anserini 与 Pyserini 的官方回归测试即用它，数值等价。

同时保留官方命令行路线，写成 `eval_official.sh`，并在评测输出中自动打印等价的 `trec_eval` 命令。这样两条路都给到用户，本机条件不同可自行切换。

2.5 执行路径总览



下载真实官方 qrels + topics (NIST 直链)

↓

安装等价评测实现 pytreceval-terrier 0.5.10

↓

构造三组对照 run → 验证指标正确性

↓

编写校验器 (把验证中发现的坑固化为检查项)

↓

编写评测脚本 (Python 路线 + 官方二进制路线)

↓

撰写清单文档 (数据集 / 工具 / 口径 / 基线 / 坑)

第三章 国内外评测竞赛的前世今生

3.1 史前阶段：Cranfield 范式 (1950s–1966)

现代检索评测的一切规矩，来自英国 Cranfield 航空学院的 Cyril Cleverdon 团队。

要素	Cranfield 的贡献	今天是否仍在用
测试集	1,398 篇航空学论文摘要	是的，只是规模换了数量级
查询集	225 条	是的
判定	穷尽式，每个 (查询, 文档) 对都判	大规模语料下已不可行
指标	查全率、查准率	是的
结论	自动索引效果不逊于手工索引	已被后续推翻重议，但方法学留了下来

Cranfield 确立的核心思想是 **Cranfield 范式**：用固定的文档集、固定的查询集、固定的标准答案，在受控条件下比较不同系统。今天所有 TREC 风格评测都是这一范式的放大版。

1970 年代陆续出现 CACM、NPL 等小规模测试集，但规模始终停留在千余篇量级。到 1990 年代初，领域公认的瓶颈是：**没有真实规模的测试集，检索研究无法验证可扩展性。**

3.2 TREC：三十四年的行业标准 (1992–2026)

诞生：1990–1991 年，DARPA 的 TIPSTER 项目委托 NIST 的 Donna Harman 构建大规模测试集，规模定为 2 GB 全文 (报纸、新闻专线)，远超当时常见的 2 MB 级实验数据。NIST 随后提议以此为基础召开评测会议，1992 年首届 TREC 召开，由 DARPA、NIST、美国国防部共同赞助。

TREC-1 (1992)：25 个研究团队参与，任务是把原型系统从检索 2 MB 文本扩展到 2 GB。两个核心任务沿用至今的变体：

- **Ad hoc**：文档集固定，查询是新的 (类似研究者用图书馆)
- **Routing**：查询固定，文档流是新的 (类似新闻剪报服务)

每届 50 个主题，每主题提交 Top 1000 结果，由 NIST 统一评测。

规模演进：1992–1999 的八届 Ad hoc 测试集合计 6 张 CD、约 189 万篇文档、450 个主题。2000 年代进入 Web 时代，GOV2 达到 2,500 万网页。2010 年代后出现 ClueWeb 系列，2020 年代 MS MARCO V2.1 达到千万级文档、上亿级段落。

方法学创新：TREC 最重要的贡献是 **pooling**——不做穷尽判定，只把各参赛系统 Top-k 结果汇总去重后送人工判定。这让大规模语料上的评测成为可能，代价是引入了"未判定即不相关"的系统性偏差。

现状（TREC 2025，第 34 届）：2025 年 12 月 11–12 日线上召开，会议录为 NIST SP 1348（2026 年 3 月出版）。十个赛道：

赛道	全称 / 方向
AVS	Ad-hoc Video Search，视频检索
BioGen	Biomedical Generative Retrieval，生物医学生成式检索
DRAGUN	新闻的检测、检索与增强生成
iKAT	Interactive Knowledge Assistance，交互式知识辅助
Million LLM	百万级 LLM 的能力识别
Product Search	商品搜索与推荐
RAG	Retrieval-Augmented Generation，检索增强生成
RAGTIME	多语言新闻报告生成 + 引用评测
ToT	Tip-of-the-Tongue，舌尖现象已知项检索
VQA	Video Question Answering

TREC 数据免费、参与开放，但官方明确规定 **TREC 结果不得用于广告宣传**。

3.3 欧洲、亚洲与其他官方评测

机构	起始	定位	与 TREC 的差异
CLEF	2000	Conference and Labs of the Evaluation Forum，欧洲	早期主打欧洲语言跨语言检索；2010 年转为独立会议；2012 年 INEX（结构化文本）并入成为 lab；现含 eHealth、LongEval、Touché、CheckThat!、SimpleText、JOKER 等
NTCIR	1999	日本 NII 主办，东亚与多语言	从零构建日语、中文测试集，解决分词等语言差异问题；覆盖 Ad hoc、CLIR、QA、专利检索、mathIR、会话检索、金融（FinNum）、Lifelog；2026 年 LREC 仍设有"26 年历程"专题

机构	起始	定位	与 TREC 的差异
FIRE	2008	Forum for IR Evaluation, 南亚	印地语、孟加拉语等南亚语言跨语言检索
TAC	2008	NIST 主办, Text Analysis Conference	偏文本分析: KBP 实体链接、RTE 文本蕴含、自动摘要
BioASQ	2012	欧盟资助的专题挑战	生物医学语义检索 + 问答, 每年多批测试集, 官方 Java 评测工具
COLIEE	2014	加拿大 Alberta 大学主办	法律案例检索 + 法律文本蕴含, 是法律 IR 最权威的官方赛事
MS MARCO	2016	微软官方竞赛	基于 Bing 真实查询日志; TREC Deep Learning Track 以其为官方测试集

MS MARCO 的特殊地位: 它不是学术机构主办, 但由微软以官方竞赛形式运营 (有排行榜、有官方评测脚本、有数据集授权协议), 并且是 TREC Deep Learning Track 2019–2023 的指定语料。这使它事实上成为稠密检索时代的官方标准测试集。

3.4 国内情况

赛事	主办方	说明
CCKS 评测	中国中文信息学会 (CIPS)	全国知识图谱与语义计算大会, 每年发布任务、数据与官方 scorer
NLPCC Shared Task	CCF	含中文检索、问答、语义匹配类任务
CCIR	CCF 全国信息检索学术会议	国内 IR 主线会议, 设评测赛道
SMP 评测	CIPS 社交媒体处理专委	社交媒体检索与匹配
CCF BDCI / DataFountain / 天池	学会 + 企业	使用企业真实搜索日志 (电商搜索、商品检索), 提供 nDCG/MRR 评测脚本
CWIRF	中文网页检索评测论坛 (早期)	中文网页测试集 CWT100G, 2000 年代的基础性工作

国内赛事有两个特点需要留意:**赛道设置每年变动大**, 须以当届官网通知为准;**多数数据赛后不公开**, 需在赛事期间报名获取。这决定了它们适合"参赛"而不适合"事后复现研究"。

3.5 演进规律

时期	驱动问题	语料规模	判定方式	主指标
1960s	自动索引是否可行	千篇	穷尽判定	P / R

时期	驱动问题	语料规模	判定方式	主指标
1992-2000	统计方法能否扩展	百万篇	pooling + 人工	MAP、P@10
2000-2015	Web 检索、垃圾页面、多样性	千万-亿级网页	pooling + 人工	nDCG、ERR、 α -nDCG
2016-2022	神经/稠密检索、跨领域泛化	千万文档/亿段落	pooling + 人工	nDCG@10、MRR@10、R@1000
2023-2026	RAG、生成式答案、归因	同左 + 多语言	LLM 自动判定 + 人工后编辑	nDCG@20/100、nugget 覆盖、支持度

最值得注意的转折在最后一行：**标准答案的 produced 方式正在从纯人工转向 LLM 主导。**

3.6 UMBRELA：判定方式的范式转移

TREC 2024 RAG Track 首次在正式评测中大规模部署 LLM 判定。UMBRELA (UMbrela is the (Open-Source Reproduction of the) Bing RElevance Assessor) 用 GPT-4o 以零样本方式对 (查询, 段落) 打 0-3 分。

官方评测流程为三段式：

- 1. **相关性判定**：UMBRELA 自动打分生成 Auto Qrels → 人工后编辑生成 Post-Edited Qrels（用于 Retrieval 任务评测）
- 2. **Nugget 构建**：LLM 从相关段落中自动抽取原子事实单元（Auto Nuggets）→ 人工增删改（Post-Edited Nuggets）
- 3. **答案评测**：对生成答案逐句做支持度（0-2：无/部分/完全）、流畅度、nugget 覆盖度判定

NIST 于 2025 年 7 月发布的大规模研究（77 个 run、19 支队伍）结论是：UMBRELA 自动判定与全人工判定在系统排序上高度相关（Kendall's τ 约 0.890），**可替代全人工用于 run 级有效性比较**；且人工介入并未显著提升相关性；人工评估员比 UMBRELA 更严格。

这一结论对任务 2 有直接价值：自建评测集时，可以先用 LLM 大规模预打标，再对分歧项人工仲裁，成本可大幅下降。

第四章 技术路线演进

4.1 检索技术的四代路线

代际	时期	代表方法	评测关注点
第一代	1960s-1990s	布尔模型、向量空间、TF-IDF、SMART 系统	查全/查准、索引效率
第二代	1990s-2010s	概率模型、BM25、语言模型、查询扩展、学习排序 (LTR)	MAP、nDCG、特征工程效果

代际	时期	代表方法	评测关注点
第三代	2016–2022	稠密向量检索（DPR、ANCE）、迟交互（ColBERT）、学习稀疏（SPLADE）、混合检索	跨领域泛化、效率与效果权衡
第四代	2023–	LLM 重排、生成式检索、RAG、智能体式深度检索	答案正确性、归因可信度、nugget 覆盖

4.2 评测方法对技术演进的适配

评测不是被动跟随技术，而是在关键节点上主动塑造了技术方向：

- **BEIR 的教训**：2021 年 BEIR 证明稠密检索器在陌生领域常输给 BM25，直接催生了混合检索与学习稀疏检索的研究热潮。
- **TREC DL 的作用**：提供了 MS MARCO 之外由组委会统一判定的测试集，避免了"自己训自己测"的循环论证。
- **查询形态的升级**：TREC DL 2023 引入 T5/GPT-4 合成查询以提高难度；TREC RAG 2025 进一步改为多句叙述型查询，倒逼系统具备多跳推理与证据聚合能力。
- **评测对象的扩展**：从"排序列表"扩展到"带引用的生成答案"，于是需要 nugget、支持度等新指标。

4.3 本任务采用的技术路线

数据层：NIST 官方 qrels + topics（真实、可校验）

↓

工具层：pytrec_eval-terrier（等价官方 C 实现）+ 官方 trec_eval 二进制（备选）

↓

校验层：格式与语义双重校验（粒度、主题覆盖、深度、排序、runtag）

↓

评测层：nDCG@10 / MAP@100 / MRR / Recall@k / P@10，口径可配置

↓

验证层：三组对照 run，用已知预期值反向验证链路

第五章 评价数据集

5.1 TREC 2025 RAG Track

语料（沿用 2024，官方公告页提供直链，需同意 MS MARCO 使用协议）：

集合	文件	记录数	体积	MD5
MS MARCO V2.1 文档集	msmarco_v2.1_doc.tar	10,960,555	28.1 GB	a5950665d6448d3dbaf7135645f1e074

集合	文件	记录数	体积	MD5
同上（分段版）	msmarco_v2.1_doc_segmented.tar	113,520,750	25.1 GB	3799e7611efffd8daeb257e9ccca4d60

格式为 70 个 gzip JSONL 打包进 tar，字段含 `docid / url / title / headings / body`。分段方式为 10 句滑动窗口、步幅 5 句，段长 500–1000 字符。文档 `docid` 编码了文件名与字节偏移（如 `msmarco_v2.1_doc_29_677149`），便于随机读取。

Topics 与 Qrels（NIST 官方直链，本任务已下载）：

类型	地址	形态
Topics（叙述型查询）	trec.nist.gov/data/rag/trec25_narratives_final.json	JSON: <code>id + narrative</code>
Topics（含子叙述）	..._w_questions_w_sub_narratives_edit_20250822.json	JSON
Qrels（文档相关性）	trec.nist.gov/data/rag/2025-rag-qrels.txt	TREC qrels, 分级 0–4
Qrels（nugget 级）	github.com/castorini/trec25-rag	官方 nuggetizer

本地实测统计：已下载的 `2025-rag-qrels.txt` 含 22 个主题、10,284 条判定，等级分布为 `{0: 3619, 1: 1499, 2: 3760, 3: 1318, 4: 88}`，平均每主题判定 467.5 条文档。官方可能分批发布，正式使用时须核对官方发布页与 overview 论文的口径与 MD5。

5.2 TREC Deep Learning Track（2021–2023）

虽已收官，仍是稠密检索最常用的官方测试集。qrels 与 topics 由 Anserini 官方维护副本发布。

用途	文件	记录数	MD5
DL21 qrels	qrels.dl21-doc-msmarco-v2.1.txt	10,973	6845b6c128aec71027e72078a960600e
DL22 qrels	qrels.dl22-doc-msmarco-v2.1.txt	349,541	ac9f5c6fcb6972d8bf13b07ab150680a
DL23 qrels	qrels.dl23-doc-msmarco-v2.1.txt	15,995	4b30e8850b6fba56289b6c177afe959b
Dev / Dev2 qrels	qrels.msmarco-v2.1-doc.dev.txt / .dev2.txt	4,702 / 5,177	089b19dce... / 8ff337f21...
DL21/22/23 topics	topics.dl21.txt / dl22.txt / dl23.txt	477 / 500 / 700	46d863434... / f1bfd53d8... / 7df9e17b4...

用途	文件	记录数	MD5
Dev / Dev2 topics	topics.msmarco-v2-doc.dev.txt / .dev2.txt	4,552 / 5,000	b05dc19f1... / f000319f1...

DL23 的 700 条查询构成为 200 条人工真实查询 + 250 条 T5 合成 + 250 条 GPT-4 合成，官方刻意提高区分难度。

5.3 TREC 2024 RAG

文件	记录数	MD5
qrels.rag24.test-umbrella-all.txt	108,479	7a43d4a23cf37f12dab0043a4b9f4d02
topics.rag24.test.txt	301	5bd6c8fa0e1300233fe139bae8288d09

官方公布的评测命令为 `trec_eval -c -m ndcg_cut.20`、`-m ndcg_cut.100`、`-m recall.100`。

5.4 数据格式规范（TREC 四件套）

件套	格式	说明
Documents	官方语料	MS MARCO 等，需自行下载
Topics	XML 或 JSON	字段 title / desc / narrative
Qrels	topic_id 0 doc_id relevance	第 2 列 0 为历史遗留占位列
Run	topic_id Q0 doc_id rank score run_tag	系统输出，6 列空白分隔

深度限制：TREC 2025 RAG 的 retrieval 子任务提交 Top-100，通用 ad-hoc 与 DL 通常为 1000。

第六章 评测指标

6.1 指标体系

指标	含义	trec_eval 写法	适用场景
nDCG@k	折损累积增益归一化	-m ndcg_cut.10	主指标，兼容二值与分级相关性
MAP	平均准确率均值	-m map	强调召回完整度
MAP@k	截断版 MAP	-M 100 -m map	深度受限场景

指标	含义	<code>trec_eval</code> 写法	适用场景
MRR	首命中倒数排名	<code>-m recip_rank</code>	已知项检索、单答案
Recall@k	前 k 条召回率	<code>-m recall.100,1000</code>	候选池质量
P@k	前 k 条准确率	<code>-m P.10</code>	首屏精确度
R-Precision	在真实相关数处的准确率	<code>-m Rprec</code>	无需指定 k
bpref	基于偏好关系的指标	<code>-m bpref</code>	判定不完整时
infAP	推断 AP	<code>-m infAP</code>	判定不完整时的替代
ERR	期望倒数排名（级联模型）	<code>-m err</code>	考虑用户浏览衰减
judged_cut@k	Top-k 中被判定过的比例	<code>-m judged_cut.10</code>	诊断用，非效果指标
α -nDCG / ERR-IA / NRBP	意图感知指标	<code>ndeval</code>	多样性、多意图查询

6.2 官方口径的三个开关

开关	作用	典型取值
<code>-c</code>	在 qrels 全量主题上平均，run 缺失的主题计 0	官方默认行为，必加
<code>-l N</code>	只有 <code>rel >= N</code> 视为相关	DL 官方口径 <code>N=2</code> ；RAG 2025 分级 0–4，常用 1 或 2
<code>-M D</code>	每主题只取前 D 条	100（RAG 提交） / 1000（ad-hoc）

`-l` 是最容易出错的一项。同一批 qrels，取 `-l 1` 与 `-l 2` 会得出完全不同的绝对数值，跨论文比较时必须确认口径一致。

6.3 指标选择建议

- 对外报告主指标报 **nDCG@10**，辅以 Recall@100。二者组合有诊断价值：Recall@100 高而 nDCG@10 低，说明候选捞到了但排序错了，重排可救；Recall@100 低则重排无解。
- 同时报 **judged_cut@10**。自建 run 命中大量未判定文档时，绝对数值不可与官方 run 横向比较，这个指标能提前暴露问题。

第七章 评测工具

7.1 NIST 官方工具

工具	语言	覆盖指标	获取
trec_eval	C	map、ndcg_cut、P、recall、 recip_rank、Rprec、bpref、iprec_at_recall、success、judged_cut、infAP、err、gm_map、set_* 系列	github.com/usnistgov/trec_eval , make 编译
ndeval	C	α -nDCG、ERR-IA、NRBP、 α -DCG	github.com/usnistgov/ndeval
gdeval	—	nDCG'（分级相关性的严格实现）	部分 TREC Web Track 采用

trec_eval 由 Chris Buckley 编写并长期维护，是事实标准。常用命令：

```
trec_eval -c -m ndcg_cut.10 -l 2 qrels.txt run.txt
trec_eval -c -M 100 -m map -m recip_rank -l 2 qrels.txt run.txt
trec_eval -c -m recall.100,1000 -l 2 qrels.txt run.txt
trec_eval -m all_trec qrels.txt run.txt # 全指标
trec_eval -q -m ndcg_cut.10 qrels.txt run.txt # 逐主题输出
```

7.2 社区等价实现

工具	说明	适用场景
pytrec_eval / pytrec_eval-terrier	Python 绑定，编译的是官方同一份 C 源码，Anserini/Pyserini 官方回归测试使用	接入自己的 pipeline；本任务采用
ir-measures	Terrier 团队维护，指标定义与官方一致，支持透传 trec_eval	批量自动化评测
ranx	纯 Python，指标丰富	快速原型

7.3 各赛事官方 scorer

CLEF 各 lab、BioASQ (bioasq-eval, Java, 算 MAP/F1/GM)、COLIEE、MS MARCO (ms_marco_eval.py, 算 MRR@10) 均提供自己的评测程序。横向比较时必须使用官方版本——第三方实现对并列分数、未标注文档等边界情况的处理不同，分数对不上。

7.4 本任务的工具选型

场景	选型	理由
沙箱/无 GitHub 环境	<code>pytrec_eval-terrier</code> 0.5.10	数值等价官方，pip 可装
本机可编译环境	官方 <code>trec_eval</code>	权威性最高，论文复现首选
提交前自检	<code>check_format.py</code>	覆盖官方硬性约束 + 两个语义坑
工具链自检	<code>make_demo_run.py</code> + oracle run	用已知预期值反证链路正确

第八章 交付成果与实测数据

8.1 成果清单

文件	作用
<code>README.md</code>	数据集清单、工具、口径、基线、坑位全表
<code>tools/check_format.py</code>	提交前格式与语义校验，退出码 0/1
<code>tools/eval_official.py</code>	指标计算（Python 路线），自动打印等价官方命令
<code>tools/eval_official.sh</code>	指标计算（官方 <code>trec_eval</code> 二进制路线）
<code>tools/make_demo_run.py</code>	反造演示 run，自检工具链
<code>data/2025-rag-qrels.txt</code>	官方真实 qrels（22 主题 / 10,284 条）
<code>data/trec25_narratives_final.json</code>	官方叙述型 topics

8.2 三组对照实验实测

在真实官方 qrels 上运行，`-l 1 -M 100`：

演示 run	nDCG@10	nDCG@100	MRR	P@10
oracle（完美排序）	1.0000	1.0000	1.0000	1.0000
shuffle（随机排序）	0.4034	0.4783	0.7765	0.6273
doclevel（粒度错配）	0.0000	0.0000	0.0000	0.0000

oracle 得到 1.0000 证明工具链与口径配置无误；doclevel 全零证明粒度错配会导致指标完全失效且不报错。

8.3 基线参考值

TREC DL 2023 passage (Anserini 官方回归)

系统	nDCG@10	MAP@100	MRR@100	R@100	R@1000
BM25	0.2061	0.0751	0.3696	0.2365	0.4514
SPLADE++ CoCondenser- SelfDistil	0.4768	0.1963	0.6985	0.4137	0.6731
SPLADE++ + Rocchio	0.4774	0.2065	0.7100	0.4226	0.7056

MS MARCO V2 doc dev (Pyserini BM25 基线)：文档级 map 0.1552 / MRR 0.1572 / R@100 0.5956 / R@1000 0.8054；分段级 map 0.1875 / MRR 0.1896 / R@100 0.6555 / R@1000 0.8542。

跑出的数值远低于 BM25 基线时，应首先怀疑粒度错配与 `-l` 口径，而不是模型能力。

第九章 关键风险与建议

风险	表现	规避
粒度错配	qrels 为 segment 级，系统按整篇检索，指标恒为 0 且不报错	用分段语料建索引； <code>check_format.py</code> [D] 项自动检查
未判定率过高	自造 run 大量命中 pooling 外文档	看 <code>judged_cut.10</code> ；论文中如实声明不可与官方 run 横向比较
<code>-l</code> 口径不一致	同一 qrels 不同阈值数值差异巨大	对照当届 overview 论文；报告中显式注明
缺主题	run 未覆盖全部主题	官方按全量主题平均，缺失计 0；用 <code>-c</code> 并跑校验器 [C] 项
表述错误	把 BEIR/MTEB 写成“官方评测”	严格区分官方竞赛与民间 benchmark
数据版本漂移	MS MARCO 版本、qrels 分批发布	下载后核对 MD5 与记录数

下一步建议：若需正式参赛或复现，优先选择 TREC 2026 RAG（官方已在征集赛道提案与参赛注册）；若仅需方法学对标，TREC DL 2021–2023 因数据完整、基线齐全而更适合。

附录 A 参考资料

1. NIST, The 34th Text REtrieval Conference TREC 2025, NIST SP 1348, 2026-03.

2. Upadhyay S. et al., Overview of the TREC 2025 Retrieval Augmented Generation (RAG) Track, arXiv:2603.09891.
3. Thakur N. et al., BEIR: A Heterogeneous Benchmark for Zero-shot Evaluation of Information Retrieval Models, arXiv:2104.08663.
4. Upadhyay S. et al., UMBRELA: UMBrela is the (Open-Source Reproduction of the) Bing RElevance Assessor, arXiv:2406.06519.
5. Upadhyay S. et al., A Large-Scale Study of Relevance Assessments with Large Language Models: An Initial Look, arXiv:2411.08275; NIST 出版物, 2025-07-18。
6. Harman D., The Text REtrieval Conference (TREC), NTCIR 主题报告。
7. Manning C. et al., Introduction to Information Retrieval, 标准测试集章节 (Cranfield / TREC / NTCIR / CLEF 规模数据)。
8. TREC RAG 官方公告页: 语料与 qrels 的 MD5 与记录数。
9. Anserini / Pyserini 官方回归文档: DL 各年基线数值与 `trec_eval` 命令。

附录 B 本地文件清单

```
/workspace/trec-eval-kit/  
├─ README.md  
├─ data/  
│   ├── 2025-rag-qrels.txt          官方 TREC 2025 RAG qrels  
│   ├── trec25_narratives_final.json 官方叙述型 topics  
│   └── run.oracle.txt / run.shuffle.txt / run.doclevel.txt  
└─ tools/  
    ├── check_format.py  
    ├── eval_official.py  
    ├── eval_official.sh  
    └── make_demo_run.py
```