

任务2调研报告

CAD 语义检索平台自建评测集方案调研

报告日期：2026 年 9 月 23 日

任务编号：任务 2

CAD 语义检索平台自建评测集方案调研

报告日期：2026 年 9 月 23 日 任务编号：任务 2 任务目标：为工程图纸（CAD / GIS）语义检索平台设计一套方法学站得住、可对甲方交付、可支撑论文表述的自建评测集方案 交付物：/workspace/cad-ir-evalkit/（方案文档 + 三个已端到端跑通的脚本 + 标注规范模板）前置依赖：任务 1 产出的 trec-eval-kit，两者 qrels 与指标脚本已打通

第一章 任务概述

1.1 提示词回溯

提示词一（需求萌发）

请问搜索引擎的评测数据集

提示词二（边界收敛）

要求官方公开举办的评测竞赛的数据集与评价工具

提示词三（任务拆分与排序）

两个都要，不过一个一个来，先完成1，再做2

提示词四（本报告成因）

请为1和2两项任务分别撰写名为"任务1调研报告.pdf"与"任务2调研报告.pdf"的文档报告，报告中，请将今天早上与任务相关的所有我发给你的提示词，以及你的深度思考过程，及如何解决任务的思路，以及重点描述任务涉及的国内外评测竞赛的前世今生，技术路线，评价数据集，评测指标与评测工具等内容

1.2 任务 2 的来源

任务 1 完成后的结论中有一条关键判断：**所有官方评测竞赛的数据集都不覆盖工程图纸领域**。用户随即确认"两个都要"，其中"2"即为：为 CAD 语义检索平台设计一套可落地的自建评测集方案。

任务 2 与任务 1 的关系不是并列，而是**方法学的迁移**：

- 任务 1：官方竞赛"有什么" → 提供方法学与工具
- 任务 2：我们有的"怎么造" → 借用方法学，用自己的数据

第二章 深度思考过程与解决思路

2.1 问题定义：真正的难点不是"造数据"

初看任务 2 是"造一批标注数据"。但按这个理解做，产出的东西在论文和甲方评审中都经不起问。真正的难点有四个，且互相耦合：

1. **粒度**：检索单元定为什么？定了就不能改，改了 qrels 全部作废。
2. **成本**：全库逐条判定不现实，如何在有限预算内让判定覆盖有意义的部分？
3. **可信度**：标注员之间不一致怎么办？多大不一致算不合格？
4. **统计功效**：只有几十个主题时，"A 比 B 高 0.03"到底算不算更好？

这四个问题在 IR 评测领域恰好都有七十年的成熟答案。因此核心思路确定为：**不发明方法，迁移方法**。

2.2 决策一：检索单元定在构件级

列出三个候选并比较：

方案	单元	判定可行性	与甲方任务的对应
A	整张图纸	粒度太粗，"这张图是否回答了 DN300 检查井的查询"难以判定	图纸归档检索
B	构件 / 图元（一个井、一段管）	每个单元可独立判定相关性	与"井与管段参数标注"对象一致
C	属性块 / 标题栏条目	上下文丢失，判定困难	字段出处追溯

选 B。决定性理由是判定可行性——评测集的每一条判定都必须能被标注员无歧义地回答，而图纸级做不到。

同时规定 docid 命名沿用 # 分段约定（图纸编号#构件序号），与任务 1 中 TREC segment 级工具链对齐，便于直接复用校验脚本的粒度检查。

2.3 决策二：用 pooling 把成本压到可承受

全库 500 条构件 × 30 主题 = 15,000 条判定，按 30 秒/条约 125 人时，不现实。

采用 TREC 的 pooling：只判各系统 Top-k 汇总去重后的文档。用 3 个系统 × Top-20，实测池子 1,742 条，降至约 14.5 人时/人，成本降到十分之一以下。

配套决定：**必须注入种子正例**。否则某些难主题的池子可能全为负例，导致该主题所有系统都得 0，既浪费标注量又扭曲均值。

2.4 决策三：一致性用加权 κ ，门槛 0.6

相关性等级是**有序**的（ $0 < 1 < 2 < 3$ ），未加权 Cohen's κ 会把"0 vs 1"和"0 vs 3"同等对待，系统性低估一致性。因此主判据定为**二次加权 κ** ，门槛 0.6。

这一选择也决定了脚本要同时输出三种统计（完全一致率、相邻一致率、严重分歧率），因为诊断时看的是分歧的**形态**而非单一数字。

另一个判断： **κ 不达标时，九成原因是 narrative 写得有歧义，不是标注员不认真**。因此把 narrative 的写法规范提升到方案的核心位置，并单列一份可直接发给标注员的指南。

2.5 决策四：显著性检验是硬要求

自建集通常只有 30–60 个主题。这个样本量下，均值差 0.03 通常不显著。若只报均值，等于说了等于没说，且容易被质疑。

因此把 paired bootstrap 作为交付的一部分（而非建议）。实测合成数据：A=0.3269 vs B=0.3615，差值 -0.0346，95% CI [-0.1010, +0.0325]，p=0.3068 → 不可宣称更优。这个数值本身就是最好的说服材料。

2.6 决策五：把坑固化成脚本，而不是写进文档

文档里写"注意粒度一致"没有人会照做。把检查项写进 `check_format.py`，让它自动报错，才有可能真正生效。同理，qrels 体检（无正例主题、主题数不足、等级分布倾斜）也做成脚本自动告警。

2.7 执行路径

```

问题定义（难点不是造数据，是方法学）
    ↓
决策1：检索单元 = 构件级
    ↓
决策2：pooling 控成本 + 种子正例
    ↓
决策3：加权  $\kappa \geq 0.6$  + narrative 规范化
    ↓
决策4：paired bootstrap 显著性
    ↓
合成数据（30 主题 / 500 构件）端到端跑通三个脚本
  
```

↓
与任务 1 工具链打通 (qrels 直接喂给官方指标脚本)
↓
撰写方案文档 + 标注规范模板

第三章 国内外评测竞赛的前世今生（方法学溯源）

任务 2 的全部方法都来自这条脉络。理解它，才知道自建时哪些能省、哪些绝不能省。

3.1 Cranfield 范式：一切的起点（1950s–1966）

英国 Cranfield 航空学院 Cyril Cleverdon 团队的工作确立了现代检索评测的基本范式：

要素	Cranfield 的做法	今天的状态
测试集	1,398 篇航空学论文摘要	规模扩大数个数量级，形式不变
查询集	225 条	形式不变
判定	穷尽式，每个（查询，文档）对都判	大规模下已不可行
指标	查全率、查准率	仍是基础

Cranfield 的核心遗产是：用固定的文档集 + 固定的查询集 + 固定的标准答案，在受控条件下比较系统。自建评测集必须遵守这一条，否则无从比较。

3.2 TREC 与 pooling 的诞生（1992 起）

1990–1991 年，DARPA TIPSTER 项目委托 NIST 的 Donna Harman 构建 2 GB 级测试集。NIST 提议以此召开评测会议，1992 年首届 TREC 召开，25 个团队参与，任务是把系统从检索 2 MB 扩展到 2 GB。

规模一上来，穷尽判定立即失效。TREC 的答案是 **pooling**：

把各参赛系统返回的 Top-k 结果汇总去重，只对这部分文档做人工判定；未出现在池中的文档在评测时视为不相关。

这一设计让大规模评测成为可能，代价是引入 **pool bias**——新系统召回池外文档会被系统性低估。这个偏差无法消除，只能承认并在报告中声明。

TREC 1992–1999 的 Ad hoc 测试集合计约 189 万篇文档、450 个主题，每届 50 个主题、每主题提交 Top 1000。这些数字成为后续自建集的尺码参照。

3.3 全球扩散：CLEF、NTCIR、FIRE、TAC

机构	起始	对方法学的贡献
CLEF	2000	欧洲语言与跨语言检索评测；2010年转为独立会议，2012年 INEX 并入；形成 eHealth、LongEval、Touché、CheckThat!、SimpleText 等 lab
NTCIR	1999	日本 NII 主办；从零构建日语、中文测试集，解决分词等语言差异；覆盖专利检索、mathIR、会话检索、金融等；2026 年 LREC 仍设"26 年历程"专题
FIRE	2008	南亚语言跨语言检索
TAC	2008	NIST 主办，KBP、RTE、摘要，偏向文本分析而非排序
BioASQ	2012	生物医学专题挑战，每年多批测试集
COLIEE	2014	法律案例检索与蕴含
MS MARCO	2016	微软官方竞赛，Bing 真实查询日志；TREC DL 2019–2023 指定语料

国内：CCKS（中国中文信息学会）、NLPCC（CCF）、CCIR（CCF 全国信息检索学术会议）、SMP（CIPS 社交媒体处理专委）设有评测赛道；CCF BDCI、DataFountain、天池等使用企业真实搜索日志；早期 CWIRF 构建了中文网页测试集 CWT100G。国内赛事赛道变动大、数据多赛后不公开，适合参赛而不适合事后复现。

3.4 最近一次范式转移：LLM 判定（2024–2026）

TREC 2024 RAG Track 首次在正式评测中大规模用 LLM 生成标准答案。UMBRELA（开源的 Bing 相关性评估器复现）用 GPT-4o 以零样本方式对（查询, 段落）打 0–3 分。

官方流程为三段：

1. **相关性：**UMBRELA 自动打分生成 Auto Qrels → 人工后编辑生成 Post-Edited Qrels
2. **Nugget：**LLM 从相关段落自动抽取原子事实单元 → 人工增删改
3. **答案评测：**逐句判定支持度（0–2）、流畅度、nugget 覆盖度

NIST 2025 年 7 月的大规模研究（77 个 run、19 支队伍）结论：UMBRELA 自动判定与全人工判定在系统排序上 Kendall's τ 约 0.890，**可替代全人工用于 run 级比较**；人工介入未显著提升相关性；人工评估员比 UMBRELA 更严格。

对任务 2 的直接价值：自建评测集可以采用"LLM 预打标 + 人工只仲裁分歧"的路线，把标注成本再压一个数量级。这是方案的可选扩展，但未写入默认流程——因为首次建集仍建议用纯人工建立可信基线，待人工基线稳定后再引入 LLM 并测量其与人工的一致性。


3.5 演进规律与自建时的取舍

时期	判定方式	主指标	自建时可否简化
1960s	穷尽判定	P / R	判定方式不可（成本不允许）
1992–2015	pooling + 人工	MAP、nDCG	方法学不可简化
2016–2022	pooling + 人工	nDCG@10、MRR	不可简化
2024–	LLM 判定 + 人工后编辑	nDCG、nugget 覆盖	可作为第二阶段降本手段

结论：**pooling + 分级判定 + 官方指标**这三件套是自建集不可省的最小集，省掉任何一件，评测结果就不可比、不可信。

第四章 技术路线

4.1 七步流程



步骤	工具	产出
① 定粒度	人工决策	docid 规范
② 设计 topics	templates/ topics_template.json	topics.json
③④ 检索 + pooling	tools/build_pool.py	pool.csv
⑤ 标注	templates/ annotation_guideline.md	两份标注 CSV
⑥ 合并 + 体检	tools/ annotations_to_qrels.py	qrels.txt + 一致性报告 + 分歧清单
⑦ 评测	../trec-eval-kit/tools/ eval_official.py	指标表
⑦ 显著性	tools/significance.py	CI + p 值

4.2 为什么必须自建

现有资源	覆盖情况
MS MARCO / TREC DL / RAG	通用网页文本，无工程构件与参数语义

现有资源	覆盖情况
BEIR / MTEB / C-MTEB	新闻、百科、医学、电商，无 CAD / 测绘 / 管网
NTCIR / CLEF / CCKS	有中文与跨语言，同样无工程图纸领域

领域空白是客观事实，也正是合理的立项动机。

4.3 与任务 1 的衔接

自建集产出的是标准 TREC qrels，因此可直接消费任务 1 的全部工具：

```
CAD 平台 → run → build_pool → 标注 → qrels.txt
                        ↓
                trec-eval-kit/eval_official.py → nDCG@10 等
```

已验证：CAD 套件生成的 qrels 喂给任务 1 脚本， $nDCG@10 = 0.3615$ ，与显著性脚本独立算出的数值完全一致。

第五章 评价数据集设计

5.1 Topics 设计

数量：最少 30，建议 40–60。低于 30 时组间差异基本不可能显著，脚本会直接告警。

来源优先级：

1. 甲方真实需求 / 历史查询日志（最有说服力）
2. 工程人员访谈整理的实际检索意图
3. 从图纸属性反向构造（保证有正解，但偏简单）

三要素结构（缺一不可）：

```
{
  "id": "101",
  "title": "钢筋混凝土检查井 DN300",
  "narrative": "需检索材质为钢筋混凝土、公称直径DN300的检查井，要求埋深参数明确且图纸来源可追溯；
    同类但材质或管径不符的判为弱相关(1分)；材质管径均符但埋深缺失的判为相关(2分)；
    材质、管径、埋深三项齐全且可定位到图号的判为完全匹配(3分)。"
}
```

narrative 是整个标注质量的生命线——它必须把“什么算 2 分、什么算 3 分”写到无歧义。 κ 不达标时九成是 narrative 太粗。

难度分布：刻意保留 20–30% 的难查询（参数缺省、别名、跨图引用）。否则所有系统分数挤在一起，区分度为零。模板中给出 easy / medium / hard 三档示例。

5.2 Pooling 参数

参数	建议值	说明
参与系统数	3-4	BM25 (Lucene)、向量检索、混合 (RRF / α 融合)、可选规则或属性过滤
每系统 Top-k	20	池深 $\approx$ 系统数 $\times$ 20 $\times$ 去重率
种子正例	每主题 1-3 条	必须注入 ，防止池子全负
随机负例对照	0 (默认不开)	能测漏召但标注量翻倍，预算充足时可对 20% 主题开启

实测参考（合成数据，30 主题 / 3 系统 / Top-20）：池子 **1,742 条**，平均 **58.1 条/主题**，按 30 秒/条约 **14.5 小时/人**，双人约 30 人时。真实场景按此量级做预算。

输出 CSV 已打乱顺序并隐藏来源，避免标注员按系统猜分。

5.3 标注规范

四级制（与 TREC DL 一致，可复用 -1 2 口径）：

分	含义	CAD 场景示例
0	不相关	查雨水口却返回管段
1	弱相关	同为检查井，但材质或管径不符
2	相关	材质、管径命中，埋深缺失
3	完全匹配	关键参数齐全且可定位到图号

边界情况处理（最常出错处）：

- 同一张图的多个构件各自独立判定，不因同图已有高分项而降分
- 属性缺失按"未命中"处理，不脑补
- 数据明显异常仍按字面判定，在 **note** 列注明
- 无法判断不留空，按最接近等级给分并注明原因

执行要求：双人独立标注，标前做 20 条校准；一致性门槛二次加权 $\kappa \geq 0.6$ ；分歧条目导出 disagreements.csv 交第三人仲裁后重跑。

5.4 与官方数据集的规格对照

维度	TREC DL 2023	TREC RAG 2025	本方案（CAD 自建）
主题数	700	22 (分批)	30-60
语料规模	千万级文档	千万文档 / 亿级段落	视项目，通常万级构件
检索单元	段落/文档	segment	构件 / 图元

维度	TREC DL 2023	TREC RAG 2025	本方案（CAD 自建）
相关性分级	0-3	0-4（按子叙述数）	0-3
判定方式	pooling + 人工	UMBRELA + 人工后编辑	pooling + 双人人工
主指标	nDCG@10	nDCG@20/100、nugget	nDCG@10

规格对齐使自建集在方法学上可被直接审视，也让外部评审能用熟悉的标准衡量。

第六章 评测指标与统计显著性

6.1 指标选择

指标	用途	注意
nDCG@10	主指标	分级 qrels 首选
MRR	已知项检索	单答案场景
P@5	首屏精确度	甲方最直观
Recall@100	候选池质量	池子有限时有偏，慎报
MAP	整体排序质量	可并列报告

Recall 在自建集上尤其危险：池子只包含各系统 Top-k 的并集，理论最大召回被池子本身锁死，报出的 Recall 既不是真实召回，也不能跨集比较。主指标应落在 nDCG 与 P@k 上。

6.2 显著性检验（硬要求）

30-60 个主题属于小样本。只报均值等于没说。标配 **paired bootstrap**（对主题重采样，B=10000），辅以 paired t 检验。

判读规则：

- 差异的 95% CI 不含 0 且 $p < 0.05 \rightarrow$ 可宣称显著
- CI 跨 0 $\rightarrow$ 只能说"数值上更高"，不可宣称更优

实测示例（合成数据，30 主题）：

项	值
A (BM25) nDCG@10	0.3269
B (混合) nDCG@10	0.3615
差值	-0.0346
95% CI	[-0.1010, +0.0325]
p 值	0.3068

项	值
逐主题胜负	A 胜 13 / 负 17
结论	不显著

数值上 B 高 0.035, 但 CI 跨 0、 $p=0.31$, 不能宣称"混合检索显著优于 BM25"。这类误判在小样本自建集上极常见。

6.3 一致性指标

指标	计算方式	用途
完全一致率	A、B 打分相同的比例	直观但不区分分歧严重程度
相邻一致率	$ \text{差} \leq 1$ 的比例	反映尺度是否稳定
严重分歧率	$ \text{差} \geq 2$ 的比例	直接指向规范缺陷
Cohen's κ	未加权	低估有序等级的一致性
二次加权 κ	权重 (	i-j

实测（注入 25% 相邻级噪声）：完全一致率 0.813、Cohen's κ 0.704、二次加权 κ 0.844、严重分歧率 0.000 → 判定达标。

第七章 评测工具

7.1 本套件工具

工具	阶段	功能
<code>build_pool.py</code>	③④	多系统 run 汇总去重、注入种子正例、可选随机负例、打乱输出待标注 CSV；自动估算标注工时
<code>annotations_to_qrels.py</code>	⑤⑥	双标注合并（四种策略）、一致性统计（三种 κ 与一致率）、分歧导出、qrels 体检
<code>significance.py</code>	⑦	paired bootstrap + paired t 检验、逐主题胜负统计、结论自动判读

7.2 复用任务 1 的官方工具

工具	用途
<code>trec-eval-kit/tools/eval_official.py</code>	官方指标计算，口径可配（-l / -M）

工具	用途
trec-eval-kit/tools/check_format.py	提交前格式与粒度校验
trec-eval-kit/tools/make_demo_run.py	工具链自检

两个套件共用 TREC 标准 qrels 格式，无需任何转换。

7.3 官方工具对照

场景	官方工具	本方案
指标计算	NIST trec_eval	pytrec_eval-terrier（同一份 C 源码）或官方二进制
一致性	TREC 用人工后编辑 + Kendall's τ	二次加权 κ + 分歧仲裁
显著性	TREC overview 常用 paired t / bootstrap	paired bootstrap (B=10000)

第八章 交付成果与实测数据

8.1 成果清单

文件	作用
README.md	完整方案：粒度决策、七步流程、topics/pooling/标注规范、指标、显著性、汇报写法
tools/build_pool.py	pooling 汇总与标注量估算
tools/annotations_to_qrels.py	标注合并、一致性报告、qrels 生成与体检
tools/significance.py	显著性检验
templates/topics_template.json	easy / medium / hard 三档 topic 写法示例
templates/annotation_guideline.md	可直接发给标注员的规范（含边界情况处理）
data/	合成示例数据（30 主题 / 500 构件 / 1,742 条判定），仅用于验证脚本

8.2 端到端实测

环节	实测结果
Pooling	30 主题 → 1,742 条待标注，平均 58.1 条/主题，约 14.5 小时/人

环节	实测结果
标注一致性	完全一致率 0.813, Cohen's κ 0.704, 二次加权 κ 0.844, 严重分歧率 0.000 $\rightarrow$ 达标
分歧导出	325 条 (18.7%) 自动导出供仲裁
qrels 体检	30 主题、1,742 条判定, 等级分布 {0:842, 1:552, 2:329, 3:19}, 全部主题均有 $\text{rel} \geq 2$ 正例
指标打通	CAD qrels $\rightarrow$ 任务 1 脚本 $\rightarrow$ $\text{nDCG@10} = 0.3615$, 与显著性脚本数值一致
显著性	示例差值 -0.0346, 95% CI [-0.1010, +0.0325], $p=0.3068 \rightarrow$ 不显著

三个脚本已在合成数据上端到端跑通, `data/` 下为示例数据, 真实使用时替换即可。

8.3 汇报与论文写法要点

必须写明的四句话 (缺一容易被质疑) :

1. 测试集规模: 主题数、判定条数、检索单元定义、docid 规范
2. 构建方法: pooling (参与系统数、Top-k、去重后池深)
3. 标注质量: 双人独立、二次加权 $\kappa = X.XX$ 、分歧仲裁机制
4. 统计口径: nDCG@10 、相关性阈值 `-l 2`、paired bootstrap $B=10000$ 、显著性结论

必须回避的两句话:

- "在标准数据集上取得 SOTA" —— 自建集不是标准数据集
- 只报均值不报 CI / p 值 —— 小样本下等于没说

关于 **pool bias** 的声明 (建议原文写入): 本测试集用于系统间**相对**比较, 绝对分数不作为通用基线; 池外文档按不相关处理, 新系统召回池外文档时其分数被系统性低估。

第九章 风险与建议

风险	表现	规避
粒度中途变更	前期 qrels 全部作废	立项时一次性拍板, 写入 docid 规范
主题数不足	差异永远不显著	起步不少于 30, 目标 40–60
难度分布失衡	全简单题, 所有系统分数趋同	强制保留 20–30% 难查询
narrative 含糊	κ 不达标, 返工重标	标前 20 条校准; κ 不达标先改规范
种子正例缺失	某主题池子全负, 所有系统得 0	每主题强制注入 1–3 条
Recall 误用	报出自欺欺人的召回率	池子有限, 主指标用 nDCG 与 $P@k$
标注漂移	长时间停顿后尺度变化	分批连续完成, 批次间做一致性抽查

分阶段建议：

- **第一阶段（本次交付）**：纯人工建立可信基线，规模 30-40 主题，产出可对外汇报的评测集
- **第二阶段**：基线稳定后引入 LLM 预打标，用人工基线测量其 Kendall's τ ，达标后转为"LLM 预打标 + 人工仲裁分歧"，成本可再降一个数量级
- **第三阶段**：若需对外对标，可将同一套方法应用于 TREC 2026 官方赛道，形成"官方集 + 领域集"双轨证据

附录 A 参考资料

1. NIST, The 34th Text REtrieval Conference TREC 2025, NIST SP 1348, 2026-03.
2. Upadhyay S. et al., Overview of the TREC 2025 Retrieval Augmented Generation (RAG) Track, arXiv:2603.09891.
3. Upadhyay S. et al., UMBRELA: UMBrela is the (Open-Source Reproduction of the) Bing RELevance Assessor, arXiv:2406.06519.
4. Upadhyay S. et al., A Large-Scale Study of Relevance Assessments with Large Language Models, arXiv:2411.08275; NIST 出版物, 2025-07-18。
5. Harman D., The Text REtrieval Conference (TREC), NTCIR 主题报告（TREC-1 起源与 pooling 机制）。
6. Manning C. et al., Introduction to Information Retrieval, 标准测试集章节（Cranfield 1,398 篇 / 225 查询；TREC 189 万篇 / 450 主题）。
7. TREC RAG 官方评测流程公告（Auto Qrels / Post-Edited Qrels / nugget 三段式）。
8. 任务 1 调研报告（本报告的方法学与工具来源）。

附录 B 本地文件清单

```
/workspace/cad-ir-evalkit/
├─ README.md                完整方案
├─ data/                    合成示例数据(可替换)
│   ├── corpus.jsonl  topics.json
│   ├── run_bm25.txt / run_vec.txt / run_hybrid.txt
│   ├── pool.csv  pool_annotated.csv  qrels.txt
├─ templates/
│   ├── topics_template.json        三档难度 topic 写法
│   └─ annotation_guideline.md      标注员规范
└─ tools/
    ├── build_pool.py
    ├── annotations_to_qrels.py
    └─ significance.py
```