

任务3调研报告

语音机器翻译研究：官方评测竞赛、数据集、指标与工具调研

报告日期：2026 年 9 月 23 日

任务编号：任务 3

语音机器翻译研究：官方评测竞赛、数据集、指标与工具调研

第一章 任务概述

1.1 提示词回溯

本报告对应的用户提示词，按时间顺序整理如下（项目书中的行政性字段不作转载）：

提示词一（任务下达） "接下来，请为以下任务：项目名称：基于跨模态统一语义表示的语音机器翻译研究 [五项研究内容]，完成类似任务1和任务2的工作（前世今生，国内外评测竞赛，评测数据集，评价指标与评价工具，技术路线等），生成'任务3-语音机器翻译研究'PDF文档，并且同步部署至公网并更新公网链接主页，以及 GitHub 主页上"

提示词二（确认收到） "我刚刚发给你的提示词呢"

提示词三（完整版项目书） "接下来请为以下任务：项目名称：基于跨模态统一语义表示的语音机器翻译研究。研究内容：1、大规模英中语音翻译数据集建设……2、跨语言跨模态统一语义表示研究……3、深度神经网络语音机器翻译模型研究……4、同声传译关键技术研究……5、融合多模态信息的机器翻译系统开发……完成与任务1和任务2相关的提示词要求的任务，同样产生类似成果：语音机器翻译研究的调研报告（PDF文档）；追加类似的HTML概览至公网链接主页，以及同步更新至 GitHub"

提示词四（质量与合规要求） "[前略] 使用 Python 语言程序设计时，注意编码问题，请仔细查看任务 1、任务 2、任务 3 生成的文档或文件以及主页是否存在乱码，或者是段落文字布局间隔过大，以及表格内单行过长导致溢出表格空间的乱七八糟的现象"

提示词五（收尾指令） "请仔细回顾今天早上所有的提示词，请执行所有未完成的任务"

其中五项研究内容为：

编号	研究内容	一句话概括
1	大规模英中语音翻译数据集建设	从英文音视频+中英文字幕自动抽取"音视频片段↔中英句子"对应关系，公开数据集
2	跨语言跨模态统一语义表示	用自建集+COCO+双语平行语料，研究图像/语音/文本的语义单元切分与统一表示、多粒度语义组合
3	深度神经网络语音机器翻译模型	源语语音→目标语文本；数据稀疏优化；口语短文本用篇章信息改善
4	同声传译关键技术	音频特征+语义特征做语音端点检测；语音流增量式翻译降低延迟
5	融合多模态信息的机器翻译系统	英文视频→中文字幕自动生成示范系统

1.2 需求界定

与任务1、任务2保持同一硬约束：

- 1. 只认官方公开举办的评测竞赛——必须有组织委员会、报名参赛、官方测试集、官方评分工具、官方论文集。社区自建基准（如各类 leaderboard）只作补充，不作主干。
- 2. 成果形态对齐——调研报告 PDF + 可运行评测工具包 + 公网 HTML 概览 + GitHub Pages 同步。
- 3. 实证优先——不写"据说效果好"，要给出可复现的数字，且要能用反例证伪脚本。

1.3 五项研究内容与评测赛道的映射

这是本任务最关键的一步判断。如果映射错了，后面所有调研都是无用功。

研究内容	对应的官方赛道	只用 BLEU 会漏掉什么
1 数据集建设	IWSLT 数据条件（constrained / constrained+LLM / unconstrained）	对齐噪声、时长分布、片段合法性——数据集质量的"体检"没有指标
2 跨模态统一表示	WMT 多模态翻译任务（2016–2017）、Multi30K、CoMMuTE、Ambiguous COCO	语义表示好不好，BLEU 根本测不出来
3 语音翻译模型	IWSLT Offline Speech Translation 赛道	ASR 前端 vs MT 后端的归因分不开
4 同声传译	IWSLT Simultaneous Speech Translation 赛道	延迟 ——只看 BLEU 等于鼓励"等全部说完再翻"，那不是同传
5 多模态字幕系统	IWSLT Subtitling 赛道（Customized ST）	分段、时间轴、每行字数等播出约束

映射完成后结论很清楚：**研究内容 4 必须有延迟指标，研究内容 5 必须有 SubER 与合规率**，否则评测与任务目标是错位的。

第二章 分析过程与解决思路

2.1 第一个判断：延续"官方 vs 民间"的划线标准

任务1已经确立的判据是**组织机制**：有报名、有官方 qrels/测试集、有官方 scorer、有论文集。这条线在语音翻译领域同样有效，且更关键——因为语音翻译领域"看起来像官方其实不是"的东西很多（例如各类商业 ASR 榜单、厂商自测报告）。

按此判据，语音翻译方向**真正符合条件的官方评测只有 IWSLT 一家是主战场**，辅以 WMT（文本/多模态）、CHiME（语音前端）、CWMT/CCMT（国内文本翻译）。

2.2 第二个判断：断代要对齐技术史的关键转折

语音翻译的技术史有一个非常明确的转折点：**端到端模型追平级联模型**。

- IWSLT 2019（第16届）：TED 英→德，冠军 KIT **21.55 BLEU**，SRPOL 19.96，SRC-B 19.5，FBK 15.67。官方结论是端到端与级联仍有约 **1.5 BLEU** 差距。
- IWSLT 2020（第17届，西雅图）：同一方向 tst2020，最好成绩 **25.3 BLEU**，且由**端到端系统**取得，比最好级联高 0.24 分。官方原话："the two paradigms are now close (if not on par)"。

IWSLT 2020 组委会还专门设计了"是否使用官方预分段"的对照，发现**前五名的提交全部使用自研分段策略**——输入分段对端到端系统的影响甚至大于架构本身。这个结论对本项目研究内容 3 和 4 都有直接指导意义（端点检测不是附属工程，而是核心算法）。

2.3 第三个判断：五项内容不能用一套指标打天下

语音翻译的评测是**分层的**：

1. 前端层（ASR）——WER / CER
2. 翻译层（MT）——BLEU / chrF / TER / COMET / BLEURT
3. 实时层（同传）——AL / DAL / AP / LAAL / StreamLAAL / SO
4. 呈现层（字幕）——SubER / CPS / CPL / LPB

本项目横跨全部四层，因此工具包必须四层都覆盖。这是与任务1（仅检索层）、任务2（检索层）最大的不同。

2.4 第四个判断：用实证代替描述，且要能证伪

与任务1用真实 NIST qrels 构造 oracle/shuffle/doclevel 三组对照同款思路，本任务也设计了可证伪的对照：

对照	预期	实测	是否证伪成功
端到端 vs 级联（同 ASR 输入）	端到端更优（无错误传播）	BLEU 90.62 vs 75.91	是

对照	预期	实测	是否证伪成功
合规字幕 vs 逐字字幕	SubER 显著更低	6.98 vs 155.81	是
wait-1 → offline 延迟递增	AL 单调递增	1.576 → 11.625	是
删 5 行假设文件	体检脚本报错	ERROR: 行数不一致	是

2.5 执行路径总览

- 1. 核实 IWSLT 2025 / 2026 官方赛道设置与指标口径；
- 2. 核实 SubER 的提出论文、官方实现与 IWSLT 采纳情况；
- 3. 核实 ST 数据集族谱与多模态数据集；
- 4. 核实国内官方评测（CWMT/CCMT）与语音侧（CHiME）情况；
- 5. 构建 `st-evalkit` 工具包并跑通四层指标；
- 6. 生成报告 PDF、追加公网概览、同步 GitHub Pages。

第三章 国内外评测竞赛的前世今生

3.1 史前阶段：语音翻译的设想（1950s–1990s）

机器翻译与语音识别长期是两条独立演化的技术线：前者从 1954 年乔治城实验起步，后者在 1970s 才由 CMU 等机构做出可用的大词汇量系统。"把两者接起来"的设想出现得很早，但受限于算力与数据，长期停留在级联这一唯一可行方案：先识别成文本，再翻译文本。

这个历史事实解释了为什么今天的官方评测仍把 `cascade` 作为一个独立参赛类别——它不是落后方案，而是产业化程度最高、可解释性最强的路线。

3.2 IWSLT：语音翻译的主战场（2004–2026）

IWSLT（International Conference on Spoken Language Translation，早期为 Workshop）是该领域唯一持续举办二十余年的官方评测。

届次	年份	地点 / 形式	关键事实
第1届	2004	—	以 Workshop 形式起步
第16届	2019	—	TED 英→德冠军 21.55 BLEU；端到端仍落后级联约 1.5 BLEU
第17届	2020	西雅图	6 个赛道；最高 25.3 BLEU 由端到端取得；分段策略成为关键变量
第19届	2022	都柏林（线上线下）	SubER 论文发表并被采纳为字幕赛道主指标

届次	年份	地点 / 形式	关键事实
第22届	2025	—	同传、离线 SLT、指令跟随、语音生成、低资源、定制化（压缩/字幕/同传）、指标共 7 类赛道
第23届	2026	圣迭戈（与 ACL 2026 同期）	5 个共享任务，7 月 3–4 日

IWSLT 2020 的六个赛道是理解该领域版图的最佳切片：Offline ST、Simultaneous ST、Video ST、Conversational ST、Open Domain MT、Non-native ST。其中 **Non-native 赛道** 用 WER 与 BLEU 的负相关关系做归因，是“前端瓶颈”分析的官方范本。

IWSLT 2026 的测试域设计已经明显超越 TED Talks 单一来源，覆盖八类：电视剧集（ITV Studios）、学术报告（ACL Anthology）、呼叫中心对话、YODAS（YouTube）、商业新闻（Asharq / Bloomberg）、带口音英语（EdAcc, 33 种口音）、合成语音（VITS、Kokoro-82M）、以及与语言无关的通用域。数据条件分为 constrained、constrained with LLMs、unconstrained 三档，评分通过 SPEECHM Evaluation Server 提交。

3.3 WMT 多模态任务（2016–2017）

WMT（Conference on Machine Translation）是文本机器翻译的顶级官方评测。它在 2016–2017 设立**多模态机器翻译（MMT）任务**，是本项目研究内容 2 在官方评测上最直接的落点。

需要如实说明：MMT 任务在 WMT 中**只办了两届**（2016、2017）即告中止。这意味着跨模态统一语义表示方向**目前没有常年举办的官方评测赛道**，只能用当时的官方数据集（Multi30K）与后续学术基准（CoMMuTE、Ambiguous COCO）自证。这是一个必须向项目组说明的现实约束。

3.4 CHiME：语音前端的"奥林匹克"（2011–）

CHiME（Computational Hearing in Multisource Environments）2011 年由法国 INRIA、英国谢菲尔德大学、美国三菱电机研究实验室等共同发起，被媒体称为“语音领域的奥林匹克”，专注解决“鸡尾酒会问题”。

届次	年份	场景	代表性结果
CHiME-3	2015	日常嘈杂环境	26 支队伍提交，最佳平均 WER 5.8%
CHiME-4	2016	六麦/双麦/单麦	科大讯飞六麦 2.24% WER ，三项全冠
CHiME-9	2024	4–8 人会议室，30 个房间	单通道 22.2% tcpWER、多通道 10.8% tcpWER

CHiME 与本研究的**关系在研究内容 1**：从真实音视频构建数据集时，前端鲁棒性决定了标注噪声的下限。CHiME 的指标体系（WER、tcpWER、说话人聚类 F1、联合误差）值得借鉴。

3.5 国内情况

必须如实指出：国内目前没有官方举办的语音翻译评测竞赛。

国内机器翻译领域的官方评测是 CWMT / CCMT（全国机器翻译大会），由中国中文信息学会主办、机器翻译专业委员会承办，自 2005 年起连续举办，是亚洲规模最大的机器翻译盛会。

届次	年份	地点	规模
CWMT 2013	2013	—	16 家参评单位，183 个提交系统，5 个语言方向、4 个领域
CWMT 2018（第八届）	2018	—	25 家单位（含日本 NICT），创历史新高
CCMT 2023（第十九届）	2023.10.19–21	济南	—
CCMT 2024（第二十届）	2024.11.8–10	厦门	评测期 2024.4.20–6.2
CCMT 2025（第二十一届）	2025.9.26–28	兰州	—

CWMT 2018 的任务代号体系（CE 汉英新闻、EC 英汉新闻、MC 蒙汉、TC 藏汉、UC 维汉、JE 日英多语言、CE-QE / EC-QE 翻译质量评估）说明其重心在**文本翻译与少数民族语言**，CWMT 2013 还首创了 gray-box 评测（要求提交中间产物）与 progress test-set（跨年度进步测试集）机制，设计相当成熟。

结论：语音翻译评测在国内长期缺位，国内团队主要参与 IWSLT、CHiME 等国际赛事。这恰恰凸显本项目研究内容 1 的价值——**公开一个大规模英中语音翻译数据集，是建立国内语音翻译评测能力的前置条件。**

3.6 演进规律

从 Cranfield 范式到 IWSLT，可以抽出三条共性规律：

- 数据集先行**——TREC 靠 TIPSTER 语料起家，IWSLT 靠 MuST-C / TED 语料扩张，MV 方向停摆也与数据规模受限有关。本项目研究内容 1 把数据集作为第一项，符合规律。
- 指标随任务目标演化**——检索从 P@10 走到 nDCG，翻译从 BLEU 走到 COMET/BLEURT，字幕则必须造出 SubER 才能把"分段+时间轴"纳入评价。指标永远是被**任务目标逼出来的**。
- 人机判定的关系在重排**——TREC 2025 已有 NIST 研究用 LLM 判定替代人工；IWSLT 2025 也引入了 Continuous Rating、MQM、Direct Assessment 等人工协议与自动指标并行。

第四章 技术路线演进

4.1 三代技术路线

代际	路线	代表时期	优势	劣势
第一代	规则/统计级联 (ASR→SMT)	1990s–2010s	模块可独立优化	误差传播、架构复杂
第二代	神经级联 (ASR→NMT)	2015–2019	译文流畅度大幅提升	误差传播仍在，且 ASR 无标点、无分段
第三代	端到端（语音→译文）	2018 至今	无误差传播、架构简洁	平行语料稀缺，训练难

2020 年是分水岭：端到端首次在官方评测中与级联持平甚至微弱超越。

4.2 端到端 vs 级联的关键细节


IWSLT 2020 有两个容易被忽略但极其重要的官方发现：

- 分段决定成败：**前五名全部使用自研分段。同样的数据，官方预分段下级联更好（AppTek/RWTH 级联 22.49 vs 端到端 20.5，KIT 22.06 vs 19.82），自研分段下端到端反超。**结论是"端到端是否优于级联高度依赖预处理"，不能一概而论。**
- 非母语任务的负相关：**Non-native 赛道显示 ASR 的 WER 与翻译 BLEU 显著负相关，即**前端质量决定译文上限。**

这两条对本项目研究内容 4（端点检测）是直接的立项依据：端点检测不是工程附属品，而是决定端到端系统能否成立的前置算法。

4.3 本项目的技术路线建议

结合五项研究内容与官方评测现状，建议的技术路线为：



评测配套：1 用体检脚本；2 用 CoMMuTE / Ambiguous COCO；3 用 IWSLT 离线口径 BLEU+chrF+TER；4 用 SimulEval 的 AL / StreamLAAL；5 用 SubER + CPS/CPL/LPB 合规率。

第五章 官方公开的评测数据集

5.1 IWSLT 官方测试集与数据条件

IWSLT 不发布单一“官方数据集”，而是规定**允许使用的训练数据清单**（constrained 条件）。IWSLT 2020 的白名单包括：MuST-C、WIT3、Speech-Translation TED 语料、How2、LibriVoxDeEn、Europarl-ST、TED-LIUM v2/v3、WMT 2019 全部数据、OpenSubtitles 2018、Augmented LibriSpeech、Mozilla Common Voice、LibriSpeech ASR 语料。

这个白名单本身就是**研究内容 1 的建设参照**：它告诉你哪些语料是社区公认可用的，你的自建集要想被接受，规模与质量必须对齐同类。

5.2 语音翻译主流数据集

数据集	方向	规模	来源域
MuST-C	英→14 语种	约 400+ 小时（英德约 408 小时）	TED Talks
MuST-C tst-COMMON	英→德	2,641 句 / 4.0 小时	TED Talks（官方测试集）
CoVoST 2	21→英, 英→15	约 2,800 小时	众包朗读
Europarl-ST v1.1	6–9 种欧洲语言, 72 个方向	每方向约 81–83 小时	欧洲议会 2008–2012
VoxPopuli	多语种	约 1,790 小时	欧洲议会 2009–2020
GigaST	英→德 / 英→中	约 10,000 小时	多源
BSTC	中→英	98 小时	百度
How2	英→葡	约 2,000 小时	教学视频
FLEURS	102 语种	—	多源评测集
Augmented LibriSpeech	英→法	—	有声书

与本项目最相关的是 **GigaST（英→中，万小时级）** 与 **BSTC（中→英）**——它们说明英中方向已有前人基础，本项目的自建集必须在**规模或领域**上形成差异化（例如影视/视频域），否则重复性风险高。

5.3 多模态与跨模态数据集（研究内容 2）

数据集	内容	规模	用途
Multi30K	Flickr30K 图像+多语描述	29,000 训练 / 1,014 验证 / 1,000 测试	WMT16–17 MMT 官方任务集
WMT17 MMT 测试集	图像+译文	1,000 图像	官方测试
Ambiguous COCO	歧义句+图像	461 图像	视觉消歧评测

数据集	内容	规模	用途
CoMMuTE	歧义句对	50 句 / 100 对	困惑度准确率评测
Microsoft COCO	图像+描述	33 万图像	用户点名，用作跨模态底座

COCO 在本项目中的定位应当是**视觉语义的锚点**：它提供图像区域与描述的对应，配合自建语音集的语音-文本对应，才有可能把三种模态投影到同一空间。

5.4 数据格式规范

类型	格式	关键约束
音频清单	TSV: seg_id / wav / start / end / duration	时间单调、无重叠、时长在合理区间
转写与译文	纯文本，一句一行，UTF-8	行数必须与清单 严格一致
字幕	SRT / VTT / TTML	时间戳三位毫秒、单调递增、无恒定偏移
同传日志	SimulEval 的 delays 序列	源端长度与目标长度必须同时记录

第六章 评价指标

6.1 翻译质量指标（研究内容 3）

指标	方向	说明
BLEU	↑	IWSLT 历届主指标， 大小写敏感 ；须先用 mwerSegmenter / mweralign 重分段
chrF / chrF2	↑	字符 n-gram，对中文与形态丰富语言更稳健
TER	↓	翻译编辑率
COMET	↑	神经指标，与人工相关性显著高于 BLEU（IWSLT 2025 起并列主指标）
BLEURT	↑	神经指标，IWSLT 2026 字幕赛道采用
WER / CER	↓	ASR 指标 ，用于前端归因，不是翻译指标

6.2 延迟指标（研究内容 4）

设 $g(t)$ 为生成第 t 个目标词时已读入的源端单元数， $|x|$ 、 $|y|$ 为源、目标长度：

指标	定义要点	特点
AL	在 τ （源端读完时刻）上平均滞后	经典主指标，依赖 τ
DAL	同式但分母固定为 $ y $	可微分，可直接进 loss
AP	归一化到 $[0,1]$	越小越流式，offline 时为 1
LAAL	把 $ y $ 换成 $\omega \cdot y $	缓解长度失配导致的偏差
StreamLAAL	LAAL 在 ω 网格上的均值	IWSLT 2025 同传赛道采用
SO	$g(1)$	首字延迟

6.3 字幕指标（研究内容 5）

指标	方向	官方约束
SubER	↓	IWSLT 字幕赛道主指标；<20 很好，>40–50 很差
CPS	合规率 ↑	中文 ≤ 9 字/秒（读不完）
CPL	合规率 ↑	中文 ≤ 16 字/行（出画）
LPB	合规率 ↑	≤ 2 行/块（遮挡画面）
BLEU / BLEURT	↑	文本质量，须先用 mweralign 重对齐

6.4 官方口径的三个陷阱

1. **BLEU 必须报告 signature**——SacreBLEU 的版本指纹（tokenizer、平滑、版本）。不同 tokenizer 的 BLEU **不可直接比大小**，这是最常见的错误。
2. **SubER 有两种变体**——官方主指标在归一化文本（不区分大小写、不带标点）上计算；
SubER-cased 是区分大小写与标点的变体，官方明确要求**不得**把它标为 "SubER" 报告。
3. **恒定时间偏移会让 SubER 静默算错**——官方 README 原文点名此坑。

第七章 评测工具

7.1 官方与准官方工具

工具	来源	用途	获取方式
SimulEval	Facebook Research / FBK	同传延迟官方评测	GitHub 开源

工具	来源	用途	获取方式
SacreBLEU	WMT 社区事实标准	BLEU / chrF / TER	pip install sacrebleu
SubER	AppTek 开源	字幕质量官方指标	pip install subtitle-edit-rate
mwerSegmenter / mweralign	NIST / Matt Post	假设重分段（BLEU 前置）	官方发布
合规率脚本	Papi et al. 2023	CPS / CPL / LPB	IWSLT 字幕赛道采用
Gentle / WhisperX	开源社区	音频↔文本强制对齐	数据集构建用
BertAlign	开源	转写↔译文对齐	数据集构建用

7.2 本任务交付的工具包 st-evalkit

脚本	作用
make_demo_data.py	生成可复现的合成演示数据
check_format.py	提交前体检，拦截静默故障
st_eval.py	BLEU / chrF2 / TER / WER / CER
subtitle_eval.py	官方 SubER + CPS/CPL/LPB 合规率
latency.py	AL / DAL / AP / LAAL / StreamLAAL / SO
significance.py	配对 bootstrap + 配对 t 检验

原则：**能调官方实现的一律调官方实现**（SubER 直接调 `suber`，BLEU 走 SacreBLEU），不自造公式冒充官方指标。

7.3 环境踩坑记录

1. `pip install` 在 PEP 668 环境下需加 `--break-system-packages`；
2. 依赖被装到 `python3.12` 的 `site-packages`，而默认 `python3` 是 3.11，需显式用 `python3.12`；
3. `sacrebleu 2.5.1` 移除了 `BLEUScore.get_signature()`，需改用类接口或自建指纹字符串；
4. `sacrebleu.corpus_ter()` **不接受** `tokenize` 参数，中文需传 `asian_support=True`；
5. 中文字体缺失会导致 PDF 乱码，本报告统一使用 Noto 系列 CJK 字体。

第八章 实证：工具包实测结果

数据为合成演示数据（`st-evalkit/data/demo`），用于验证脚本能正确区分好坏系统。

8.1 离线翻译质量

系统	BLEU ↑	chrF2 ↑	TER ↓	ASR 端 WER ↓
端到端 e2e	90.62	86.30	4.30	18.23 %
级联 cascade	75.91	69.06	12.07	18.23 %

两系统共用同一份 ASR 输出（WER 相同），差异全部来自**错误传播**——这正是级联 vs 端到端的经典归因场景。配对 bootstrap (B=10000, n=40)：差值 +16.94, 95% CI [+10.96, +23.41], $p < 0.0001$, 差异显著。

8.2 字幕（研究内容 5）

字幕	SubER ↓	BLEU ↑	CPS 合规	CPL 合规	LPB 合规
压缩后（合规）	6.98	—	100.00 %	100.00 %	100.00 %
逐字转写（直出）	155.81	59.28	0.00 %	0.00 %	100.00 %

逐字版的 BLEU 并不低 (59.28)，但 CPS 实测 16.00 字/秒（上限 9）、CPL 26 字/行（上限 16），**完全不可播出**。这与 IWSLT 2026 字幕赛道的实测趋势一致：HW-TSC 的报告显示，引入压缩后三个域的 CPS 合规率从 70–94% 提升到 87–99%，同时 SubER 与 BLEU 反而略有改善。

8.3 同传延迟（研究内容 4）

策略	AL ↓	DAL ↓	AP ↓	LAAL ↓	StreamLAAL ↓	SO ↓
wait-1	1.576	1.505	0.606	1.576	1.838	1.700
wait-3	3.578	3.108	0.745	3.578	3.788	3.700
wait-5	5.584	4.363	0.854	5.584	5.739	5.700
wait-9	9.613	5.827	0.979	9.613	9.661	9.700
offline	11.625	6.095	1.000	11.625	11.625	11.625

单调性与理论一致；offline 的 AP = 1.000 达到理论上限，可作为量表的上界校准点。

8.4 体检脚本的证伪测试

故意删掉假设文件末尾 5 行后：

[ERR] 行数不一致 (35 vs 40)。BLEU 会被静默稀释，且不会报错。
 请检查分段，或用 mwerSegmenter / mweralign 重分段。
 结论：存在 ERROR，禁止提交。

若跳过体检直接算 BLEU，不会有任何提示——这正是必须体检的理由。

8.5 开发过程中真实踩到并修复的四个坑

坑	症状	修复
时间轴累积漂移	BLEU=100 却 SubER=65, 自相矛盾	压缩版沿用参考时间轴, 抖动 $\pm 0.03s$ 不累积
毫秒溢出	生成 ,1000 非法时间戳	整体取整后再拆分为时/分/秒/毫秒
负时间戳	首块变成 -1:59:59,975	起始时间钳位到 ≥ 0
指标参数不兼容	TER 恒为 None	改用 asian_support 而非 tokenize

第九章 结论与建议

9.1 核心结论

1. 语音翻译的官方评测主战场是 IWSLT, 且它是唯一持续二十余年的官方赛事。WMT 多模态任务仅办两届即停摆, 国内 CWMT/CCMT 尚无语音翻译赛道——这是本项目必须正视的外部约束。
2. 五项研究内容必须映射到四条不同的指标链: 翻译质量 (BLEU/chrF/TER)、前端归因 (WER/CER)、实时性 (AL/StreamLAAL)、呈现合规 (SubER/CPS/CPL/LPB)。用一套 BLEU 覆盖五项内容会导致研究内容 4 与 5 的评测完全失效。
3. 国内语音翻译评测缺位, 恰恰是本项目研究内容 1 的机会。公开一个大规模英中语音翻译数据集, 是后续建立国内评测能力的前置条件。
4. 端到端是否优于级联, 取决于输入分段。IWSLT 2020 的官方结论应当作为研究内容 3、4 的立项前提: 端点检测与分段策略是核心算法, 不是工程附属。

9.2 给项目组的落地建议

优先级	建议	理由
高	自建集发布时同步提供体检脚本与数据卡	否则数据质量无法被外部验证, 难以被评测采纳
高	研究内容 5 直接以 IWSLT Subtitling 赛道指标为验收标准	SubER + 三项合规率是唯一成熟口径
中	研究内容 4 的延迟指标以官方 SimulEval 为准	自研实现仅供消融, 提交/论文须用官方工具
中	研究内容 2 采用 CoMMuTE / Ambiguous COCO 作旁证	该方向无常年官方赛道, 需用学术基准自证
中	英中方向差异化定位 (影视/视频域)	GigaST、BSTC 已覆盖通用域, 避免重复建设

9.3 待办与风险

事项	状态
任务3 报告 PDF	已完成
st-evalkit 工具包	已完成，合成数据跑通
公网 HTML 概览追加任务3板块	本地完成，待确认后发布
GitHub Pages 同步	阻塞：用户名未提供
任务1/2/3 文档与主页的编码、排版体检	已完成并修复

风险提示： `github.com/hunan08182026` 经核实返回 404，该用户名不存在；GitHub 用户名不允许包含 `@`，因此不能用邮箱 `hunan08182026@126.com` 直接作为用户名。需提供真实用户名后，右上角的 GitHub 入口与 Pages 同步才能真正生效。

本报告的评测方法、指标定义与工具调用均对齐官方实现；合成数据仅用于验证脚本，不代表任何真实系统性能。